Projeto AM 2026-2

Francisco de A. T. de Carvalho[1]

1 Centro de Informatica-CIn/UFPE
Av. Prof. Luiz Freire, s/n -Cidade Universitaria, CEP 50740-540, Recife-PE, Brasil,
fatc@cin.ufpe.br

Questão 1

- Considere a base de dados "spambase" (Arquivos anexados com o projeto, https://archive.ics.uci.edu/dataset/94/spambase)
- Use a ferramenta da sua escolha (scikit learn https://scikit-learn.org/stable/, WEKA https://www.cs.waikato.ac.nz/ml/weka/, etc)
- Execute o k-means 100 vezes com $k \in \{2, 3, 4, 5\}$. Para cada k (executado 100 vezes) selecione o melhor resultado segundo a função objetivo. Para cada k, calcule a silhueta (Sil). Faça o plot $Sil \times k$ para $k \in \{2, 3, 4, 5\}$ e escolha o número de grupos: $k* = art \max_k Sil(k)$.
- Assuma que os clusters são as verdadeiras classes. Desconsidere a variável resposta original e acrescente uma nova variável resposta one os valores possíveis para os exemplos são entre 1 e $k*$. Use os 5 (cinco) classificadores abaixo:
  - i) Arvores de decisão; ii) Bayesiano ingenuo; iii) Regressão logistica; iv) k-vizinhos (Use conjunto de validação para fixar o par (número de vizinhos k,distância)); v) Random forest.
- Separe de maneira aleatoria e estratificada (proporcional ao numero de exemplos de cada classe) os dados em treinamento, teste e, se necessário, validação. Sugestão: 80% para treinamento + validação e 20% para teste.

Questão 1 (cont.)

Treine o classificador no conjunto de treinamento. Teste o classificador no conjunto de teste. Se o modelo possuir hiper-parametros, use validação cruzada para fixar os hiper-parametros. O conjunto de teste não pode ser usado no treinamento e na escolha dos valores dos hiper-parametros.

Tentar melhorar cada um dos classificadores escolhido, procurando os melhores hiperparâmetros para alcançar a melhor precision (precisão), cobertura (recall) e f1-score no conjunto de teste.

- Para cada metrica de avaliação, plot a curva de aprendizagem para os classificadores com a melhor configuração de hiper-parametros. Mais precisamente, considere conjuntos de treinamento e teste de $(5\%, 95\%)$ a $(95\%, 5\%)$ do conjunto original de dados, com passo de 5% (usando amostragem estratificada). Para cada par de conjuntos de treinamento e teste, calcule as metricas de avaliação em cada um desses conjuntos. Comente.

Observações Finais

- No Relatório deve estar bem claro como foram organizados os experimentos de tal forma a realizar corretamente a avaliação dos modelos e a comparação entre os mesmos. Fornecer também uma descrição sucinta dos dados. No relatorio mostrar os detalhes da obtenção dos hiper-parametros do modelo, se houver.
- Data de apresentação e entrega do projeto: **QUARTA-FEIRA 30/09/2026 a partir das 12:30 horas, sala E122**.
- Um dos membros da equipe: **colocar no google classroom o relatório do projeto, e os slides da apresentação. Me avisar por e-mail quando colocar**.
- **NÃO COLOCAR ARQUIVO ZIPADO**
- Tempo de apresentação: **10 minutos** para cada equipe (**rigoroso**).
- **A presença e a participação de todos os membros de cada equipe é obrigatória durante a apresentação**;