



UNIVERSIDADE FEDERAL DE PERNAMBUCO

CAMPUS RECIFE

CENTRO DE INFORMÁTICA

APRENDIZADO DE MÁQUINA

Gabriel Stamford Arnaud

Matheus Augusto Monte Silva

Pedro Henrique Dantas Soares

Samuel Celso dos Anjos Neto

Relatório de Projeto de Aprendizado de Máquina com o Spambase

Recife

2026

1. Especificação do projeto

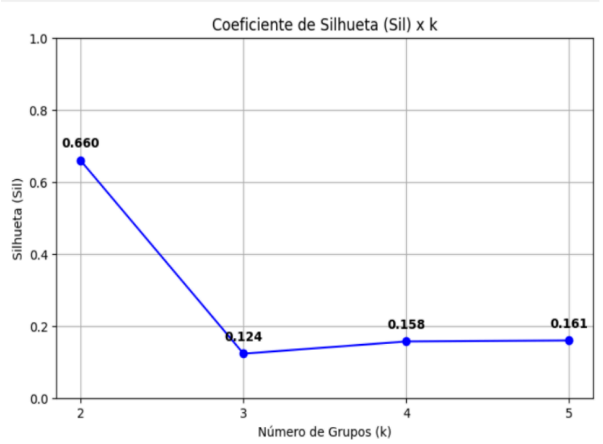
O projeto tem como objetivo principal avaliar o desempenho de diferentes algoritmos de aprendizado de máquina em um cenário de reclassificação de dados por meio do *dataset Spambase*, tal que a especificação propõe ignorar os rótulos originais de classificação (spam ou não spam) e aplicar o algoritmo não supervisionado *K-means* (com diferentes métodos de normalização e PCA) para gerar um novo agrupamento dos dados, que será utilizado como o "novo rótulo".

A partir desses novos rótulos, que se mostraram altamente desbalanceados, o projeto realiza a implementação e avaliação preditiva de cinco modelos de aprendizado supervisionado: *K-Vizinhos (KNN)*, *Naive Bayes*, *Árvore de Decisão*, *Random Forest* e *Regressão Logística*. A metodologia requer o tratamento desse desbalanceamento através de técnicas de reamostragem (*Random Oversampling* e SMOTE), o uso de Validação Cruzada, a extração de métricas de desempenho (F1-Score, Precisão e *Recall*) e a construção de Curvas de Aprendizagem para compreender a capacidade de generalização e estabilidade topológica de cada modelo nas fronteiras de decisão.

2. Introdução

Nesse contexto, a parte inicial do projeto consistiu em executar o k-means cem vezes para cada valor de k indo de dois a cinco. De tal forma que como o k-means é sensível à inicialização, utilizou-se o menor valor da função objetivo como critério para se determinar qual execução dentre as cem foi a "melhor". Ademais, para escolher o k "ideal", selecionou-se aquele que apresentou a melhor (maior) métrica silhueta.

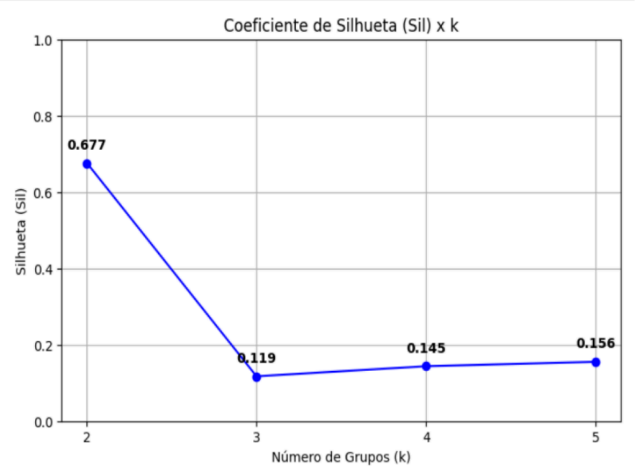
Vale ainda ressaltar que para viabilizar a execução do k-means, uma vez que ele se baseia na distância entre os dados, normalizou-se o dataset por meio das técnicas: StandardScaler; MinMaxScaler; RobustScaler. Todas indicaram k igual a dois como o k "ideal", com maior valor de silhueta, com valores de 0.660, 0,677 e 0.938, respectivamente. Entretanto, considerando que o dataset original tinha classes quase balanceadas, com 2788 não spam e 1813 spam, as três técnicas de normalização formaram grupos muito desbalanceados, 4567/34, 4568/33 e 4589/12, como ilustrado pelas Figuras 1, 2 e 3, respectivamente.



Nova_Classe	
2	4567
1	34

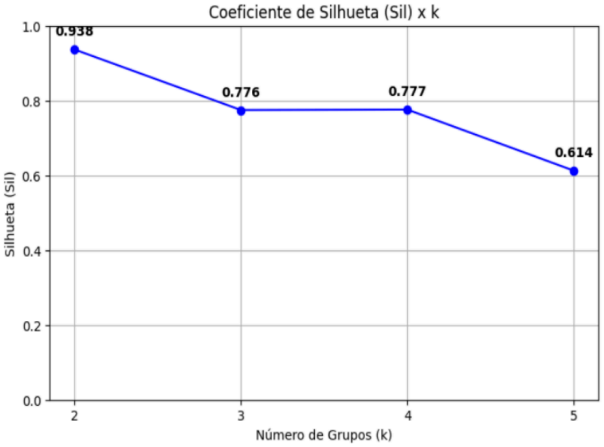
Figura 1. Valor de Silhueta para StandardScaler e agrupamento gerado pelo

valor de k = 2 (melhor valor)



Nova_Classe	
1	4568
2	33

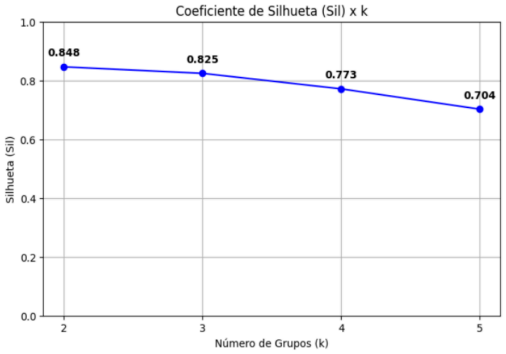
Figura 2. Valor de Silhueta para MinMaxScaler e agrupamento gerado pelo valor de k = 2 (melhor valor)



Nova_Classe	
1	4589
2	12

Figura 3. Valor de Silhueta para RobustScaler e agrupamento gerado pelo valor de k = 2 (melhor valor)

Nesse contexto, houve uma grande perda de informação na clusterização dos dados e isso possivelmente trará problemas para os algoritmos que serão executados posteriormente. Assim como sugerido na especificação do projeto, utilizou-se os clusters como os rótulos "verdadeiros" para os algoritmos supervisionados. Com o intuito de contornar essa perda, rodou-se o k-means sem a normalização dos dados, retornando ainda o k ideal como sendo 2 (valor de 0,848 para silhueta) e uma partição ainda muito desbalanceada de 4357/244, como mostra a Figura 4.



Nova_Classe	
1	4357
2	244

Figura 4. Valor de Silhueta para caso Sem Normalização e agrupamento gerado pelo valor de k = 2 (melhor valor)

Dessa maneira, testou-se usar PCA antes de rodar o k-means visando uma partição mais balanceada, sem precisar introduzir ruído sintético via oversampling, sobre os dados sem normalização e com StandardScaler. Entretanto, o PCA foi utilizado de tal maneira que no cenário de normalização usando StandardScaler, reduziu-se o problema de 57 para 48 dimensões, mas gerou uma partição idêntica à gerada pela normalização Standard. Enquanto no cenário sem normalização, reduziu-se o problema de 57 para 2 dimensões, gerando-se também uma partição idêntica à gerada pelos dados sem normalização. Nesse sentido, descartou-se essa solução e fixou-se o agrupamento gerado pelo StandardScaler sem PCA para "criar os novos rótulos".

3. Metodologia

Para a avaliação preditiva dos modelos de aprendizado supervisionado, estabeleceu-se um pipeline padronizado de processamento e validação. Inicialmente, o conjunto de dados original é dividido em duas partes: 80% dos dados são destinados aos conjuntos de treinamento e validação, enquanto os 20% restantes são reservados exclusivamente para o teste. Essa divisão é realizada antes de qualquer etapa de normalização ou balanceamento e ocorre por meio de uma amostragem estratificada, ou seja, a proporção das diferentes classes da variável resposta é preservada tanto no conjunto de treinamento/validação quanto no conjunto de teste. Para garantir a reprodutibilidade dos resultados, utiliza-se uma semente aleatória fixa (*random_state=42)*.

Os 80% destinados ao treinamento e à validação são então utilizados em um procedimento de validação cruzada com cinco folds (5-fold cross-validation). Nesse procedimento, o conjunto de 80% é dividido em cinco subconjuntos. Em cada iteração, quatro subconjuntos são utilizados para treinamento e o subconjunto restante é utilizado para validação, alternando-se o subconjunto de validação até que todos os cinco folds tenham sido utilizados. O desempenho obtido nas cinco iterações é posteriormente agregado via média aritmética simples, sendo utilizada como métrica de seleção a F1-macro.

Dentro de cada iteração da validação cruzada, com exceção do Naive Bayes, é realizado inicialmente o processo de normalização por meio do *StandardScaler* (essencial para algoritmos baseados em distância, especialmente o KNN), que é ajustado exclusivamente sobre os folds contendo os dados de treinamento. Assim, o fold contendo os dados de validação são apenas transformados utilizando-se os parâmetros aprendidos no respectivo conjunto de treinamento. Dessa forma, as informações estatísticas utilizadas para a padronização não são obtidas a partir dos dados de validação, evitando vazamento de

informação durante a validação cruzada.

Após a normalização, são avaliadas três estratégias distintas relacionadas ao tratamento do desbalanceamento das classes. A primeira estratégia corresponde à utilização do modelo correspondente sem qualquer técnica de oversampling, servindo como modelo de referência (*baseline*). A segunda estratégia utiliza o Random Oversampling, que aumenta a representação das classes minoritárias por meio da replicação de observações existentes. A terceira estratégia utiliza o SMOTE (Synthetic Minority Over-sampling Technique), que, em vez de simplesmente duplicar observações, cria novas amostras sintéticas para as classes minoritárias com base na estrutura de vizinhança dos dados. De tal forma que tanto o Random Oversampling quanto o SMOTE são executados exclusivamente sobre os dados de treinamento de cada fold da validação cruzada. Isso é fundamental para evitar *data leakage*. Em outras palavras, os dados pertencentes ao subconjunto de validação não são utilizados para gerar novas amostras sintéticas nem são duplicados durante o processo de oversampling.

Ademais, para cada uma das três estratégias, sem balanceamento, Random Oversampling e SMOTE, é realizado um Grid Search com validação cruzada, cujo objetivo é selecionar os melhores hiperparâmetros do classificador em questão. De tal maneira que após a realização da validação cruzada, o Grid Search identifica, para cada estratégia de balanceamento, a combinação de hiperparâmetros que apresentou o melhor desempenho médio segundo o F1-macro. O melhor pipeline de cada estratégia é então reajustado utilizando a totalidade dos 80% originalmente destinados ao treinamento e à validação. Nesse momento, o StandardScaler é ajustado utilizando todos esses 80% e, caso a estratégia selecionada envolva oversampling, o Random Oversampling ou o SMOTE é aplicado somente a esse conjunto de treinamento completo.

Por fim, para avaliar a capacidade de generalização dos classificadores parametrizados com suas melhores configurações, foram plotadas curvas de aprendizagem variando a volumetria do conjunto de treinamento. Atendendo às diretrizes do projeto, o conjunto de dados original foi iterativamente particionado de (5%, 95%) até (95%, 5%), utilizando passos de 5% sob amostragem estratificada. Para cada incremento de volume, os algoritmos tiveram seus desempenhos mensurados tanto nos dados de treinamento quanto nos de teste, utilizando a média macro para as métricas de Precision, Recall e F1-Score.

3.1 Procedimento de modelagem e avaliação do classificador K-vizinhos

Seguindo o pipeline metodológico geral estabelecido, os hiperparâmetros avaliados no KNN durante o processo de validação cruzada foram: o número de vizinhos (k), variando para todos os valores entre 1 e 20, e a métrica de distância, na qual foi explorada a família de distâncias de Minkowski, sendo avaliados os valores de p indo de 1 até 5 (lembrando que o caso p=1 corresponde à distância Manhattan, enquanto p=2 corresponde à distância Euclidiana), além de ser avaliada a distância de Chebyshev (p tendendo ao infinito).

Curiosamente, todos os cenários de oversampling apresentaram o mesmo resultado, selecionando como melhores parâmetros 1 para K e 2 para p (distância euclidiana), com melhor score de 1 para o F1-Score. Nesse sentido, o objetivo inicial era escolher “o melhor” conjunto de parâmetros como sendo aquele que retornasse o melhor score para só então rodar o k-vizinhos com tais parâmetros no conjunto de teste, uma vez que uma ordem inversa implicaria em um *data leak* indireto. Porém, nesse contexto, decidiu-se rodar os três cenários no conjunto de teste e comparar os resultados. Novamente, todos apresentaram mesmos resultados, obtendo máximo desempenho em todas as métricas: acurácia total, precision,

recall e f1-score por classe e, consequentemente, nas versões macro de precision, recall e f1-score.

Esse resultado sugere fortemente uma influência direta da partição gerada pelo k-means no k-vizinhos, com este último fazendo um "caminho inverso" do k-means, se apropriando da distância euclidiana e de clusters bem homogêneos para escolher k igual a 1.

Destarte, a análise visual da curva de aprendizagem do classificador KNN, a partir da Figura 5, revela o comportamento estrutural do classificador diante da topologia artificial gerada pelo agrupamento prévio do K-Means. Em relação à curva de treinamento (azul), ela permanece constante em 1.0 em todas as métricas observadas por causa da mecânica do KNN quando avaliado sobre os próprios dados de treinamento com hiperparâmetro $k = 1$: o vizinho mais próximo de qualquer vetor será sempre ele próprio a uma distância euclidiana nula, sempre garantindo acerto.

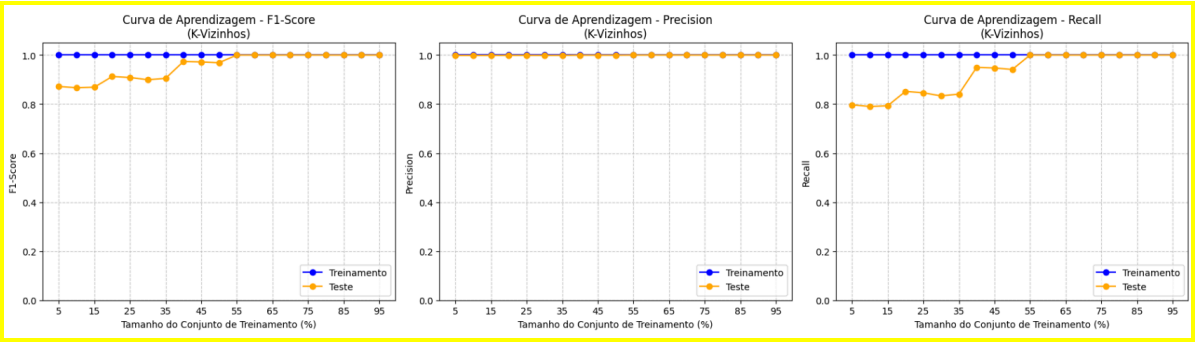


Figura 5. Curva de Aprendizagem para KNN parametrizado com distância euclidiana e k = 1

Quanto à curva de teste, a métrica de precisão aparenta estabilidade absoluta em 100%, mas um olhar minucioso revela uma levíssima não-sobreposição entre teste e treino nas proporções menores que 55%. Essa ilusão visual se deve à equação da média *macro* lidando com densidades assimétricas entre os agrupamentos. Em outras palavras, muito provavelmente a classe minoritária não recebe Falsos Positivos, pois a massa de "dados normais" (do cluster com mais elementos) não "invade" sua região anômala extrema, travando a precisão da minoria em 1.0. Simultaneamente, os erros reais do modelo (pontos minoritários errados) se tornam Falsos Positivos para a classe majoritária; contudo, como o volume de Verdadeiros Positivos da classe maior está na casa dos milhares, o acréscimo de um ou dois erros no denominador afeta o resultado de forma microscópica (ex: $3600/3602 \approx 0.999$).

Já a métrica de Recall (e, consequentemente, F1-Score) desmascara os erros de classificação, registrando pontuações na faixa de 0.80 no conjunto de teste com 5% de dados e escalando progressivamente até atingirem a perfeição na marca de 55%. Esse valor "baixo" inicial mapeia fisicamente a fronteira entre os dois agrupamentos. Com apenas 5% de volume de treinamento, o particionamento estratificado disponibiliza apenas 2 vetores da classe minoritária para a memória do k-NN. Assim, caso um vetor de teste dessa classe esteja localizado no limite da fronteira divisória, a escassez de elementos da mesma classe (minoritária) no hiperplano faz com que ele localize um vetor da classe majoritária como seu vizinho mais próximo, provocando um Falso Negativo e afundando o Recall específico da

minoria. À medida que a amostragem avança para 55%, a linha de fronteira é melhor populada por vetores de treinamento, eliminando a "cegueira" espacial do KNN e equalizando as linhas de treino e teste.

A fim de atestar essa hipótese sobre o comportamento topológico do modelo na fronteira de decisão, realizou-se uma extração direta das métricas isoladas por classe utilizando exatos 30% de volume de treinamento. O objetivo foi observar melhor como se deram os erros de classificação entre os agrupamentos. Nesse contexto, a Classe 1 (minoritária) apresentou um suporte de 24 instâncias, registrando um *Recall* de 0.6667 e *Precision* de 1.0. Dessa maneira, o *Recall* indica que o algoritmo classificou corretamente 16 vetores (Verdadeiros Positivos), mas falhou na identificação de 8 instâncias (Falsos Negativos), enquanto a precisão intocada atesta que absolutamente nenhum vetor da nuvem majoritária invadiu o espaço isolado da minoria.

Por sua vez, a Classe 2 (majoritária) contou com um vasto suporte de 3197 instâncias e alcançou um *Recall* absoluto de 1.0, capturando todos os seus elementos originais. Contudo, sua *Precision* registrou 0.9975, ou seja, os 8 Falsos Negativos que escaparam da Classe 1 foram rotulados como Falsos Positivos na Classe 2. Ao reconstruir a fórmula da precisão para a massa majoritária ($TP/(TP + FP)$), a razão exata se torna $3197/(3197 + 8)$, cujo resultado de 0.9975 bate rigorosamente com a métrica aferida pelo algoritmo. Esse exemplo permite uma melhor visualização do que ocorre entre as fronteiras dos clusters e como isso afetou o desempenho do KNN.

Vale ainda ressaltar que mais um teste foi feito a fim de atestar o porquê do agrupamento gerado pelo caso sem normalização ser pior. Nele, se gerou a sua curva de aprendizagem e observou-se que nenhuma das métricas convergia, independente do *split* entre os conjuntos de treinamento e teste, evidenciando que a distância euclidiana foi totalmente enviesada pela grandeza das três últimas features, gerando, assim, uma topologia corrompida.

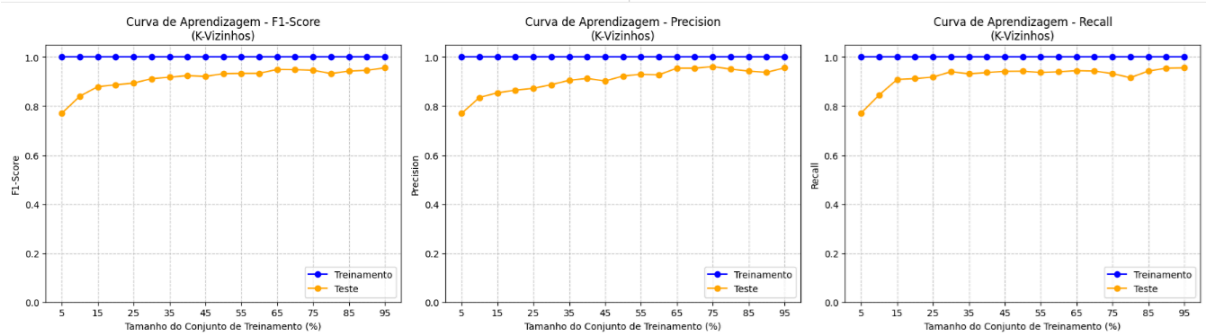


Figura 6. Curva de Aprendizagem para KNN no caso Sem Normalização, parametrizado com distância euclidiana e k = 1

3.2 Procedimento de modelagem e avaliação do classificador Naive Bayes

Diferentemente do KNN, o classificador utilizado neste cenário foi o Naive Bayes Gaussiano (*GaussianNB*), não sendo necessária uma etapa de normalização por meio do *StandardScaler*. O classificador estima os parâmetros das distribuições das características para cada classe. A formulação utilizada assume que as características são condicionalmente independentes dada a classe e que suas distribuições podem ser aproximadas por distribuições gaussianas.

Seguindo a aplicação das três estratégias de balanceamento (baseline, Random Oversampling e SMOTE), o Grid Search explorou o hiperparâmetro *var_smoothing*, avaliado em diferentes valores na escala logarítmica. Esse parâmetro controla a suavização aplicada às variâncias estimadas pelo classificador, contribuindo para a estabilidade numérica das estimativas probabilísticas.

Após a realização da validação cruzada, o Grid Search identifica, para cada estratégia de balanceamento, a configuração que apresentou o melhor desempenho médio segundo o F1-macro. No cenário sem balanceamento, o melhor valor encontrado para *var_smoothing* foi 10^-6, obtendo F1-macro médio de aproximadamente 0,7900. Para o Random Oversampling, o melhor valor foi 10^-7, com F1-macro médio de aproximadamente 0,7488. Por fim, o cenário utilizando SMOTE apresentou o melhor desempenho médio entre as três estratégias, selecionando *var_smoothing* igual a 10^-7 e alcançando F1-macro médio de aproximadamente 0,8096.

Nesse sentido, o SMOTE apresentou o maior desempenho durante a validação cruzada, indicando que o aumento da representação da classe minoritária por meio da geração de amostras sintéticas contribuiu para o desempenho médio do Naive Bayes durante o processo de seleção do modelo. Entretanto, o Random Oversampling apresentou desempenho inferior ao cenário sem balanceamento e ao cenário utilizando SMOTE, indicando que a simples replicação das observações minoritárias não proporcionou melhoria para este classificador no conjunto de dados utilizado.

Quando os modelos selecionados são aplicados ao conjunto de teste, o desempenho é mensurado por meio do relatório de classificação, contendo métricas como precisão, revocação (recall), F1-score e suporte para cada classe, além das médias agregadas. No cenário sem balanceamento, a Classe 1 apresentou *precision* de 0,47, *recall* de 1,00 e F1-score de 0,64, enquanto a Classe 2 apresentou *precision* de 1,00, *recall* de 0,99 e F1-score de 1,00. O F1-macro obtido foi de aproximadamente 0,82.

No cenário utilizando Random Oversampling, a Classe 1 apresentou *precision* de 0,33, *recall* de 1,00 e F1-score de 0,50, enquanto a Classe 2 apresentou *precision* de 1,00, *recall* de 0,98 e F1-score de 0,99. Consequentemente, o F1-macro foi reduzido para aproximadamente 0,75.

Por sua vez, o cenário utilizando SMOTE apresentou, para a Classe 1, *precision* de 0,44, *recall* de 1,00 e F1-score de 0,61. Para a Classe 2, foram obtidos *precision* de 1,00, *recall* de 0,99 e F1-score de 1,00, resultando em F1-macro de aproximadamente 0,80.

Os resultados devem ser interpretados considerando a elevada assimetria entre as classes produzidas pelo agrupamento anterior. No conjunto de teste, a Classe 1 apresentou apenas 7 instâncias, enquanto a Classe 2 apresentou 914 instâncias. Dessa maneira, a acurácia e as médias ponderadas tendem a ser fortemente influenciadas pela classe majoritária, tornando a média macro uma métrica mais adequada para observar o comportamento do classificador sobre as duas classes.

É possível observar ainda que o maior F1-macro obtido na validação cruzada pelo cenário utilizando SMOTE não se reproduziu no conjunto de teste, no qual o cenário sem balanceamento apresentou F1-macro ligeiramente superior. Isso evidencia a diferença entre o desempenho médio observado durante a validação cruzada e o desempenho obtido em uma partição de dados que não participou da seleção do modelo.

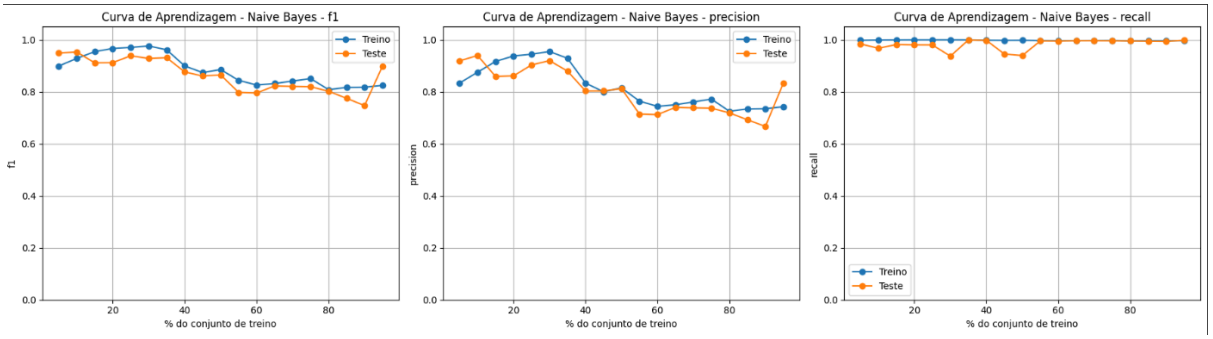


Figura 7. Curvas de Aprendizagem para o classificador Naive Bayes parametrizado com SMOTE e var_smoothing = 10^{-7}.

A curva de aprendizagem do Naive Bayes, Figura 7, apresenta um comportamento relativamente estável para o F1 ao longo das diferentes proporções do conjunto de treinamento, embora seja possível observar uma redução gradual das métricas à medida que a quantidade de dados utilizada para treinamento aumenta. No treinamento, o F1 inicia próximo de 0,90, atinge valores próximos de 0,98 entre 25% e 35% dos dados e posteriormente apresenta uma redução, estabilizando-se em torno de 0,82. No conjunto de teste, o F1 apresenta maior oscilação, iniciando próximo de 0,95 e atingindo valores próximos de 0,93 na faixa de 25% a 35%, antes de apresentar uma redução gradual até aproximadamente 0,75 em 90% dos dados. No último ponto, correspondente a 95% do conjunto utilizado para treinamento, observa-se uma elevação do F1 no teste para aproximadamente 0,90.

Ao analisar separadamente precision e recall, observa-se que a principal responsável pelas variações do F1 é a precision, enquanto o recall permanece elevado durante praticamente toda a curva. O recall do treinamento permanece próximo de 1,00 em todas as proporções, enquanto no teste apresenta apenas pequenas oscilações, com uma redução mais perceptível em torno de 30% e 50% dos dados, mas retornando posteriormente para valores próximos de 1,00. Dessa forma, o modelo consegue identificar a maior parte das instâncias pertencentes às classes, mantendo poucos falsos negativos.

Por outro lado, a precision apresenta uma redução mais evidente conforme a proporção utilizada para treinamento aumenta. No treinamento, a métrica parte de aproximadamente 0,83 e atinge valores próximos de 0,95 no início da curva, mas posteriormente reduz-se gradualmente até aproximadamente 0,74. No teste, a precision inicia próxima de 0,92, apresenta algumas oscilações nas primeiras proporções e posteriormente diminui até aproximadamente 0,66 em 90% dos dados. Essa diferença indica que, embora o modelo mantenha um recall elevado, ocorre um aumento relativo de classificações positivas incorretas, o que reduz a precision e, consequentemente, o F1.

Ademais, as oscilações observadas no conjunto de teste devem ser interpretadas considerando que, à medida que a proporção de treinamento aumenta, o conjunto utilizado para avaliação diminui. Dessa forma, nos últimos pontos da curva, pequenas alterações nas instâncias presentes no conjunto de teste podem produzir variações mais perceptíveis nas métricas. Esse comportamento é particularmente relevante neste experimento devido ao forte desbalanceamento entre as classes produzidas pelo K-means. Consequentemente, a redução observada na precision não implica necessariamente uma deterioração uniforme do modelo

em todas as classes, sendo necessário considerar também a composição dos exemplos presentes em cada divisão.

Em síntese, a curva evidencia que o Naive Bayes mantém recall elevado e relativamente estável, enquanto a precision apresenta maior sensibilidade à quantidade de dados utilizada e à composição dos conjuntos de avaliação. Como consequência, o comportamento do F1 acompanha principalmente as variações observadas na precision. Ainda assim, as curvas não apresentam uma separação excessivamente elevada entre treinamento e teste, indicando que o comportamento observado não é caracterizado por uma diferença acentuada entre as duas curvas ao longo de todo o experimento.

Vale ressaltar que esse classificador teve uma atitude praticamente contrária ao KNN, uma vez que este último preferia arriscar dizer que um elemento da classe minoritária era da majoritária, enquanto o Naive Bayes fez o oposto.

3.3 Procedimento de modelagem e avaliação do classificador Árvore de Decisão

Apoiando-se no pipeline metodológico padronizado, o modelo de Árvore de Decisão manteve a etapa de normalização via StandardScaler nos dados de treinamento para assegurar consistência na sua avaliação frente às três estratégias de balanceamento. Durante a otimização pelo Grid Search, buscou-se os melhores hiperparâmetros referentes à estrutura geométrica da árvore, como: o critério de divisão (criterion), a profundidade máxima (max_depth) e o número mínimo de amostras para divisão (min_samples_split).

Após a realização da validação cruzada, o Grid Search identificou que a melhor configuração em todas as estratégias de balanceamento foi alcançada utilizando o critério 'gini', sem limite de profundidade (max_depth: None) e min_samples_split igual a 2. No cenário sem balanceamento, o F1-macro médio foi de 0,9753. Utilizando o Random Oversampling, a métrica apresentou uma leve queda para 0,9627. O cenário com SMOTE alcançou um F1-macro médio de 0,9719. Assim como observado em outros modelos, a introdução de dados sintéticos ou duplicados não superou a performance do modelo baseline nos dados originais.

Ao aplicar o melhor modelo (sem balanceamento) no conjunto de teste, os resultados demonstraram alta capacidade preditiva. A Classe 1 (minoritária, com apenas 7 instâncias) apresentou precision de 0,8750, recall de 1,0000 e F1-score de 0,9333. A Classe 2 (majoritária, com 914 instâncias) obteve precision de 1,0000, recall de 0,9989 e F1-score de 0,9995. O F1-macro consolidado no teste foi de 0,9664. A precisão de 0,8750 na classe minoritária e o recall de 0,9989 na classe majoritária refletem de forma exata a matemática do modelo: o algoritmo encontrou perfeitamente os 7 verdadeiros positivos da minoria, mas cometeu um único erro (Falso Positivo) ao classificar 1 das 914 instâncias majoritárias como minoritária (7/8 = 0,8750 e 913/914 = 0,9989)

Quanto à curva de aprendizagem, a análise visual da Figura 8 revela um comportamento esperado para uma Árvore de Decisão sem limite de profundidade: a curva de treinamento (azul) permanece reta e constante em 1,0 em todas as métricas, evidenciando que o modelo memoriza perfeitamente os dados de treino. No conjunto de teste (laranja), observa-se uma forte instabilidade inicial. Com proporções menores de dados (5% a 30%), as métricas de Precision e Recall oscilam significativamente, apresentando vales próximos a 0,78 e 0,83, respectivamente. Essa oscilação decorre da natureza geométrica não-linear do

algoritmo tentando mapear a fronteira isolada do cluster gerado pelo K-Means. À medida que o volume de dados de treinamento ultrapassa os 85%, a árvore dispõe de informações suficientes para traçar divisões ortogonais perfeitas, e a curva de teste converge para 1,0, espelhando a métrica de treino.

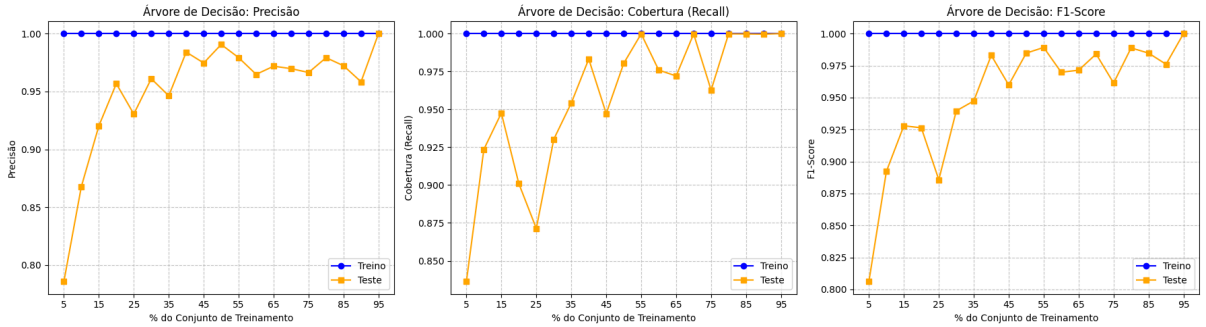


Figura 8. Curva de Aprendizagem para Árvore de Decisão

3.4 Procedimento de modelagem e avaliação do classificador Random Forest

A metodologia de divisão dos dados, validação cruzada, normalização e aplicação das estratégias de balanceamento (Random Oversampling e SMOTE) seguiu rigorosamente os mesmos parâmetros descritos para a Árvore de Decisão. Para o classificador Random Forest, um método ensemble que combina múltiplas árvores de decisão, o Grid Search explorou hiperparâmetros adicionais, notadamente o número de estimadores (n_estimator), além da profundidade máxima (max_depth) e divisão mínima de amostras (min_samples_split).

Durante a validação cruzada, a estratégia sem balanceamento obteve o melhor desempenho absoluto, registrando um F1-macro médio de 0,9888 utilizando 100 estimadores (n_estimators: 100), sem limite de profundidade (max_depth: None) emin_samples_split: 2. Os cenários com Random Oversampling e SMOTE selecionaram 50 estimadores e apresentaram, ambos, um F1-macro idêntico de 0,9811. Novamente, o modelo baseline manteve a superioridade.

A aplicação do melhor modelo de Random Forest no conjunto de teste revelou um fenômeno preditivo notável: o algoritmo obteve pontuação 1,00 (100% de acerto) em todas as métricas (Precision, Recall e F1-Score) para ambas as classes. Ao contrário de uma única Árvore de Decisão, que cometeu falsos positivos isolados devido à rigidez de suas ramificações, o ensemble de 100 árvores corrigiu os erros individuais através da votação majoritária. Esse resultado indica que o Random Forest conseguiu realizar uma "engenharia reversa" perfeita das complexas fronteiras geométricas multidimensionais previamente estabelecidas pelo algoritmo K-Means.

A avaliação da capacidade de generalização através das curvas de aprendizagem, Figura 9, reforça a robustez do método ensemble, uma vez que a curva de precisão no conjunto de teste (verde claro) parece apresentar fortes oscilações, mas a observação do eixo Y desmistifica essa ilusão visual: os valores flutuam em uma margem microscópica entre 0,9984 e 1,0000. Isso significa que, mesmo com apenas 5% de dados de treino, o modelo quase não comete falsos positivos.

As métricas de Cobertura (Recall) e F1-Score revelam o verdadeiro aprendizado do modelo. Nas menores proporções de treino, o algoritmo enfrenta dificuldade para rastrear os raros exemplos da classe minoritária, resultando em quedas de Recall até a faixa de 0,80. Contudo, superando a instabilidade típica da Árvore de Decisão isolada (vista na subseção anterior), as curvas do Random Forest demonstram menor variância real e convergem de forma mais consistente para a perfeição (1,0) à medida que o volume de treino se aproxima dos 85%. A linha de treinamento verde escuro, inabalável no topo (1,0), confirma a capacidade ilimitada do modelo de decorar os dados vistos, enquanto as curvas de teste validam seu excepcional poder de generalização frente às fronteiras estabelecidas pelo clusterizador.

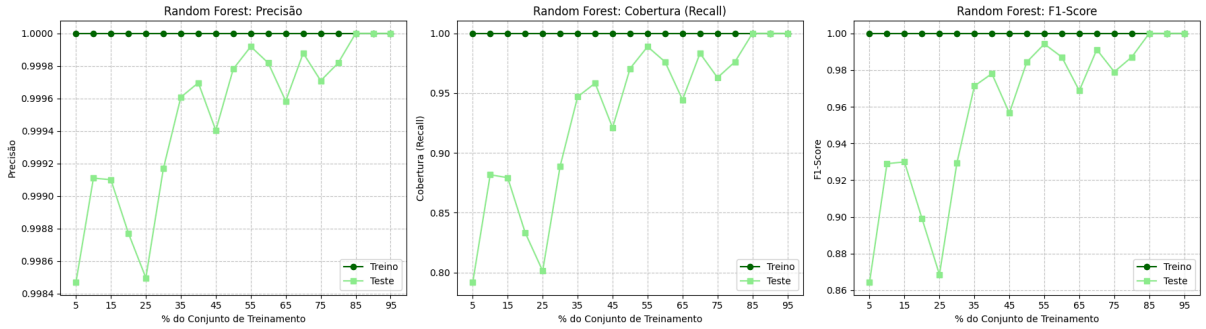


Figura 9. Curva de Aprendizagem para Random Forest

3.5 modelagem e avaliação do classificador Regressão Logistica

O algoritmo de Regressão Logística foi incorporado ao *pipeline* metodológico padronizado, exigindo a etapa preliminar de normalização dos dados pelo *StandardScaler* em cada *fold* de treinamento, dada a sensibilidade de métodos baseados em otimização de gradiente à escala das variáveis. Para lidar com a forte assimetria das classes, o modelo foi exposto aos três cenários de tratamento estabelecidos: ausência de balanceamento (*baseline*), *Random Oversampling* (ROS) e SMOTE.

A otimização do modelo foi delegada ao *GridSearchCV*, que explorou exaustivamente diferentes hiperparâmetros para encontrar o hiperplano de separação ideal. A grade de busca testou as penalidades de regularização *L1* (utilizando o *solver* liblinear) e *L2* (utilizando o *solver* lbfgs), variando a força da regularização inversa (C) em uma escala de 0,001 a 100, e fixando o limite máximo de iterações (max_iter) em 5000 para assegurar a convergência matemática do algoritmo.

Durante a Validação Cruzada (5-*folds*), o modelo sem balanceamento superou as demais estratégias, atingindo um *F1-Score Macro* médio perfeito de 1,0, empregando a penalidade *L2*, o *solver* lbfgs e $C = 0,1$. A aplicação do SMOTE e do ROS gerou desempenhos médios ligeiramente inferiores (0,9764 e 0,9753, respectivamente). Esse comportamento evidencia que o agrupamento original já apresentava uma separabilidade topológica clara o suficiente para o classificador, tornando redundante a introdução de ruído sintético ou de instâncias duplicadas no espaço paramétrico.

Ao submeter o modelo *baseline* otimizado ao conjunto de teste (20% isolados), o relatório de classificação confirmou sua alta capacidade preditiva. Na Classe 1 (minoritária, representada por apenas 7 instâncias no teste), o algoritmo obteve *Recall* absoluto de 1,00 e

Precisão de 0,88. Na Classe 2 (majoritária, com 914 instâncias), tanto a Precisão quanto o *Recall* marcaram 1,00, resultando em um *F1-Score Macro* consolidado de 0,97. A precisão de 0,88 atesta que o hiperplano gerado pelo modelo discriminou corretamente todos os 7 verdadeiros positivos da classe minoritária, cometendo apenas um número residual de Falsos Positivos ao classificar instâncias da zona de fronteira.

A Curva de Aprendizagem da Figura 10 revela que, diferentemente dos algoritmos geométricos baseados em distância pura, a curva da Regressão Logística expôs um traçado de aprendizado progressivo nas parcelas mais baixas de dados (entre 5% e 25%), onde o modelo ainda calibrava os pesos do seu hiperplano separador. As métricas de *Precisão* e *Recall* no conjunto de teste acompanharam as linhas do conjunto de treinamento de forma extremamente coesa, exibindo oscilações microscópicas iniciais antes de se estabilizarem próximas a 1,0.

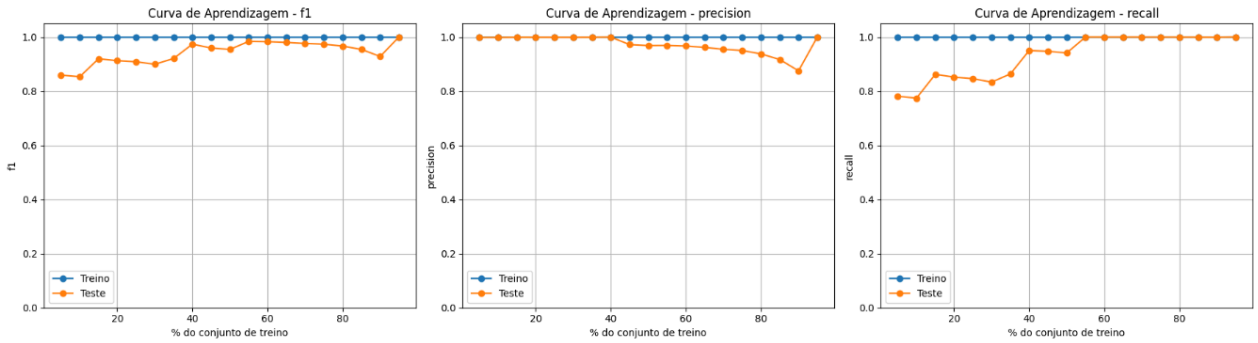


Figura 10. Curva de Aprendizagem para Regressão Logística

Em síntese, o comportamento exibido nas curvas comprova que as fronteiras demarcadas na fase não supervisionada pelo *K-Means* resultaram em agrupamentos linearmente separáveis no espaço multidimensional. Isso permitiu que a Regressão Logística capturasse rapidamente o padrão linear dos dados sem sofrer com *overfitting* (sobreajuste), exibindo poder de generalização elevado mesmo quando treinada com frações reduzidas da amostra total.

4. Conclusão

Este projeto teve como objetivo central avaliar o desempenho de cinco algoritmos de aprendizado supervisionado (K-Vizinhos, Naive Bayes, Árvore de Decisão, Random Forest e Regressão Logística) em um cenário de reclassificação do dataset Spambase. A metodologia proposta envolveu a substituição dos rótulos originais por agrupamentos gerados pelo algoritmo não supervisionado K-Means, seguida pelo tratamento do desbalanceamento de classes resultante e a otimização dos modelos por meio de validação cruzada (*Grid Search*).

A etapa inicial de clusterização com o K-Means revelou-se um ponto de inflexão crítico para o estudo. A aplicação de técnicas de normalização, essenciais para algoritmos baseados em distância, resultou na seleção de $k = 2$ como o número ideal de grupos, maximizando o coeficiente de silhueta (alcançando 0.938 com RobustScaler, 0.677 com MinMaxScaler e 0.660 com StandardScaler). Contudo, essa reclassificação gerou uma topologia altamente assimétrica e desbalanceada, com um agrupamento majoritário

concentrando a quase totalidade das instâncias e um agrupamento minoritário extremamente reduzido. Tentativas de mitigar esse efeito, como a execução do K-Means sem normalização ou a aplicação prévia de PCA, não resultaram em partições mais balanceadas ou introduziram perda significativa de informação, consolidando a escolha da normalização via StandardScaler para a definição dos "novos rótulos".

Outrossim, a avaliação subsequente dos classificadores supervisionados evidenciou como a topologia criada pelo K-Means impactou o aprendizado. Notavelmente, os modelos baseados em fronteiras lineares ou regras geométricas simples, como a Árvore de Decisão e o Naive Bayes, apresentaram desafios iniciais para mapear a região isolada da classe minoritária, refletindo-se em oscilações nas métricas de precisão e recall durante as fases iniciais das curvas de aprendizagem. Por outro lado, modelos com maior capacidade de generalização e adaptação geométrica demonstraram resultados superiores.

O modelo Random Forest, beneficiando-se da natureza *ensemble* para corrigir os erros individuais das árvores de decisão, apresentou um desempenho notável, alcançando pontuação máxima no conjunto de teste e demonstrando estabilidade mesmo com volumes reduzidos de dados de treinamento. De forma análoga, a Regressão Logística demonstrou que os agrupamentos estabelecidos pelo K-Means eram linearmente separáveis no espaço multidimensional, atingindo rapidamente a convergência sem sofrer de *overfitting*. Curiosamente, o KNN, operando com $k = 1$ e distância euclidiana, realizou essencialmente uma "engenharia reversa" do K-Means, apropriando-se da homogeneidade dos clusters para também alcançar precisão quase perfeita no conjunto de teste.

Ademais, outro achado significativo do estudo foi a avaliação das técnicas de reamostragem (Random Oversampling e SMOTE). Em todos os cenários analisados, a introdução de ruído sintético ou a duplicação de instâncias não superou o desempenho absoluto dos modelos *baseline* (sem balanceamento) nos dados originais durante a validação cruzada. Isso sugere que, neste cenário específico, a separabilidade topológica original gerada pelo K-Means era forte o suficiente para dispensar a manipulação artificial das classes.

Em síntese, o estudo demonstra que a reclassificação de dados por meio de algoritmos não supervisionados pode criar fronteiras de decisão altamente definidas, porém assimétricas. A escolha e o desempenho do classificador supervisionado subsequente dependem intrinsecamente de sua capacidade de mapear essa nova topologia. Os resultados obtidos com o Random Forest e a Regressão Logística destacam sua robustez frente a agrupamentos gerados de forma não supervisionada, fornecendo *insights* valiosos sobre a interação entre os paradigmas de aprendizado de máquina em *pipelines* de dados complexos.