APRENDIZAGEM DE MÁQUINA

SPAM

Gabriel Stamford Arnaud (gsa6)
Matheus Augusto Monte Silva (mams4)
Pedro Henrique Dantas Soares(phds3)
Samuel Celso dos Anjos Neto (scan)

EDA

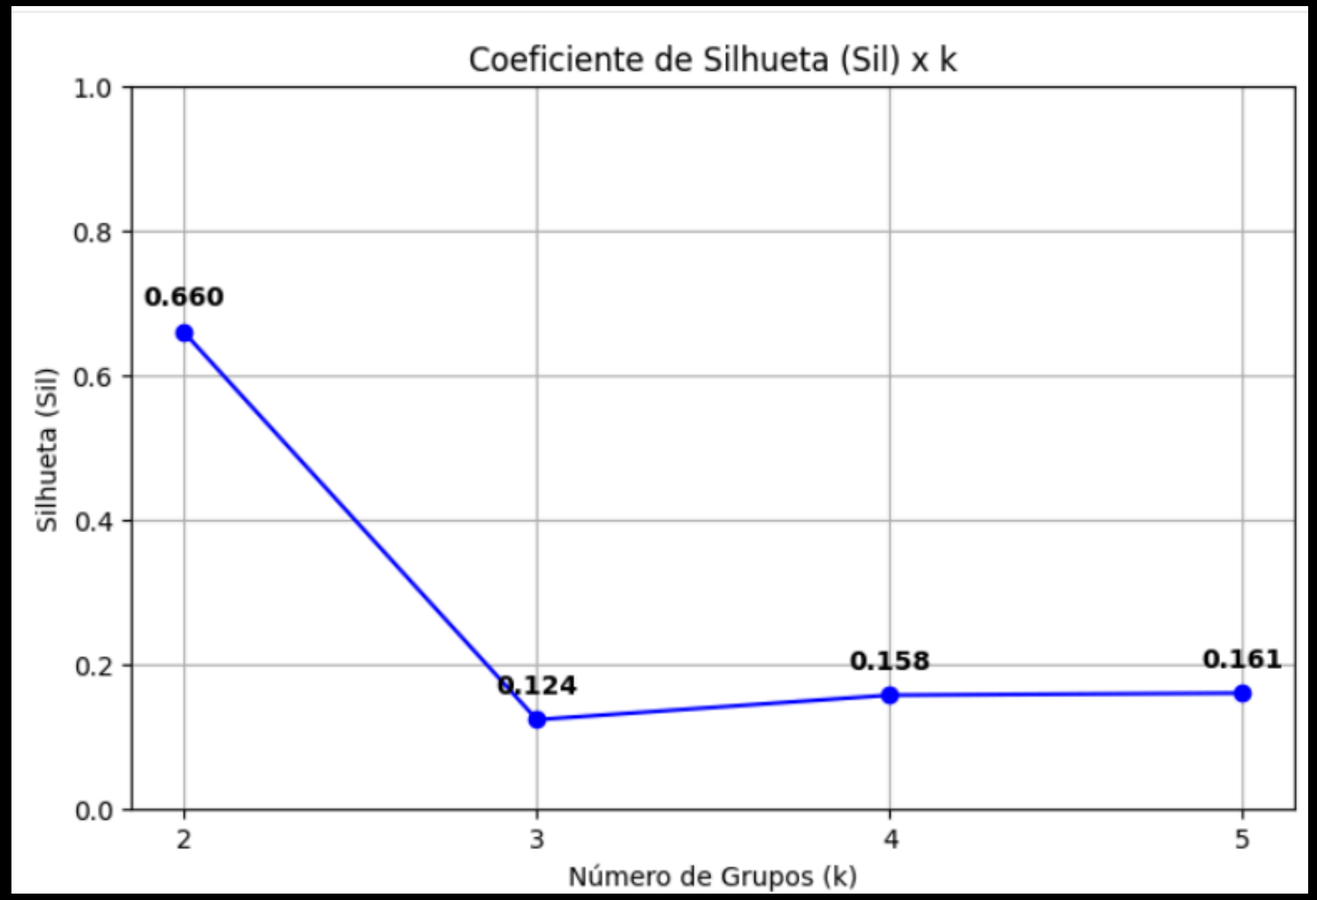
	0	1	2	3	4	5	6	7	8	9	...	48	49	50	51	52	53	54	55	56	57
0	0.00	0.64	0.64	0.0	0.32	0.00	0.00	0.00	0.00	0.00	...	0.00	0.000	0.0	0.778	0.000	0.000	3.756	61	278	1
1	0.21	0.28	0.50	0.0	0.14	0.28	0.21	0.07	0.00	0.94	...	0.00	0.132	0.0	0.372	0.180	0.048	5.114	101	1028	1
2	0.06	0.00	0.71	0.0	1.23	0.19	0.19	0.12	0.64	0.25	...	0.01	0.143	0.0	0.276	0.184	0.010	9.821	485	2259	1
3	0.00	0.00	0.00	0.0	0.63	0.00	0.31	0.63	0.31	0.63	...	0.00	0.137	0.0	0.137	0.000	0.000	3.537	40	191	1
4	0.00	0.00	0.00	0.0	0.63	0.00	0.31	0.63	0.31	0.63	...	0.00	0.135	0.0	0.135	0.000	0.000	3.537	40	191	1

	0	1	2	3	4	5	6	7	8	9	...	48	49	50	51	52	53	54	55	56	57
1488	0.19	0.00	0.38	0.00	0.00	0.19	0.00	0.00	0.00	0.00	...	0.010	0.010	0.000	0.000	0.000	0.003	2.383	21	15841	1
1753	0.00	0.00	0.00	0.04	0.00	0.00	0.00	0.00	0.00	0.00	...	1.024	9.752	0.003	1.542	1.785	1.998	239.571	9989	10062	1
904	0.29	0.04	0.04	0.00	0.14	0.04	0.00	0.29	0.29	0.94	...	1.117	0.053	0.000	0.356	0.090	0.011	12.332	1171	9163	1
679	0.00	0.00	0.28	0.00	0.16	0.18	0.00	0.00	0.00	0.00	...	0.000	0.116	0.021	0.034	0.000	0.000	16.587	154	9090	1
675	0.00	0.00	0.28	0.00	0.16	0.18	0.00	0.00	0.00	0.00	...	0.000	0.116	0.021	0.030	0.000	0.000	16.644	154	9088	1

FEATURES COM VALORES MUITO DISCREPANTES => NORMALIZAR DADOS

NORMALIZAÇÃO → KMEANS

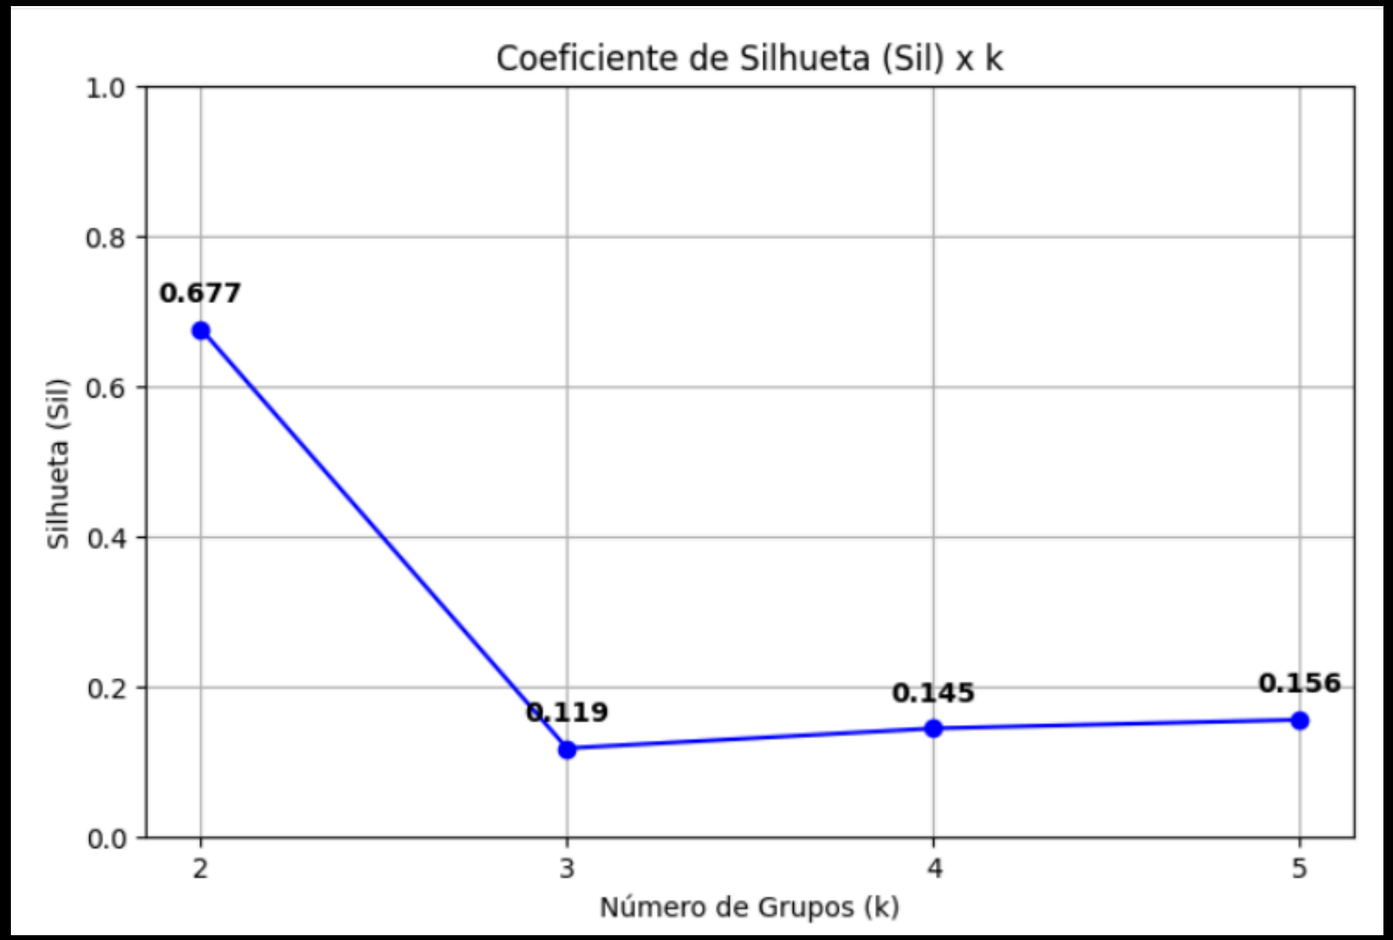
STANDARDSCALER



Nova_Classe	
2	4567
1	34

NORMALIZAÇÃO → KMEANS

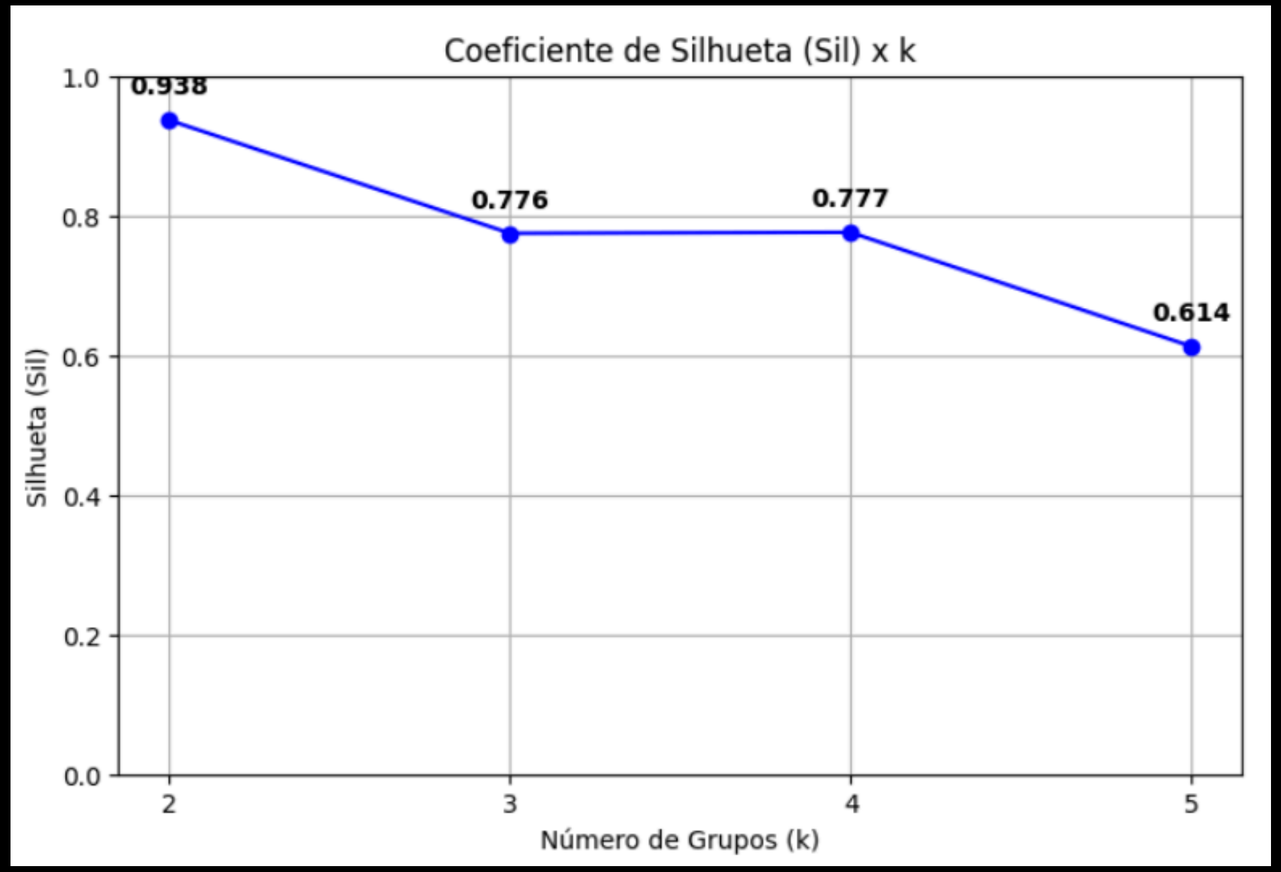
MINMAXSCALER



Nova_Classe	
1	4568
2	33

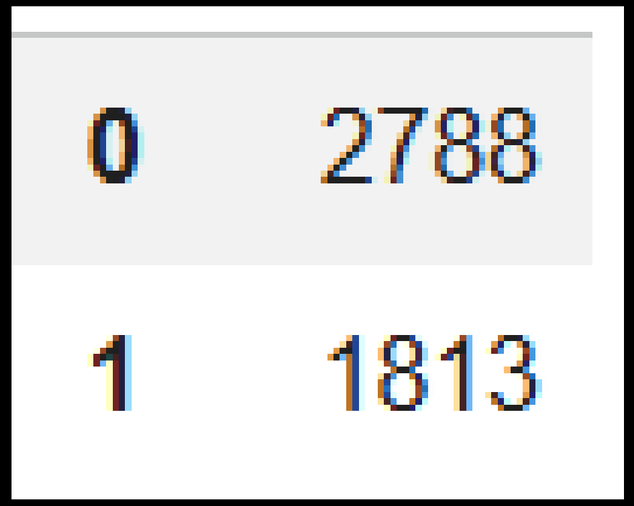
NORMALIZAÇÃO → KMEANS

ROBUSTSCALER
(MENOS SENSÍVEL A OUTLIERS)



Nova_Classe	
1	4589
2	12

AGRUPAMENTOS DESBALANCEADOS

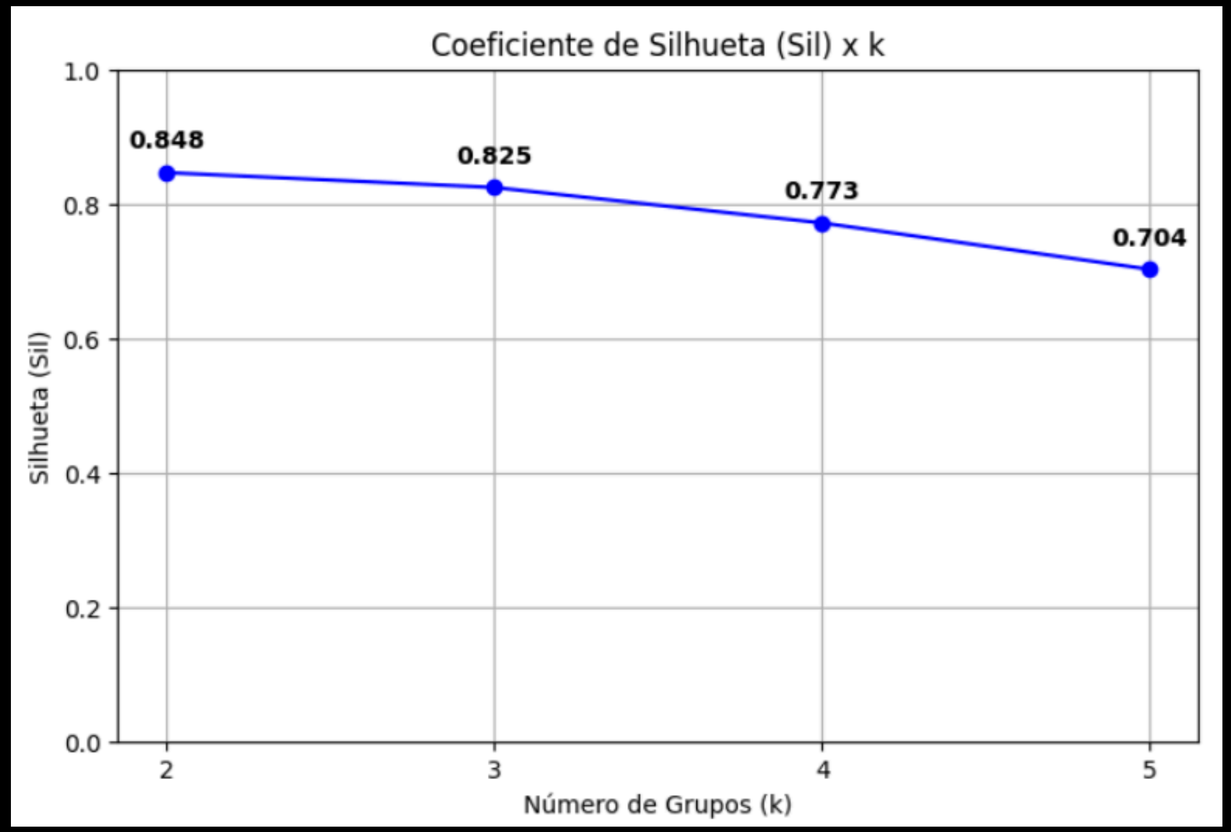


AGRUPAMENTO ORIGINAL
1 = SPAM

SEM NORMALIZAÇÃO

PCA:
1) SEM NORMALIZAÇÃO
2) STANDARD

SEM NORMALIZAÇÃO

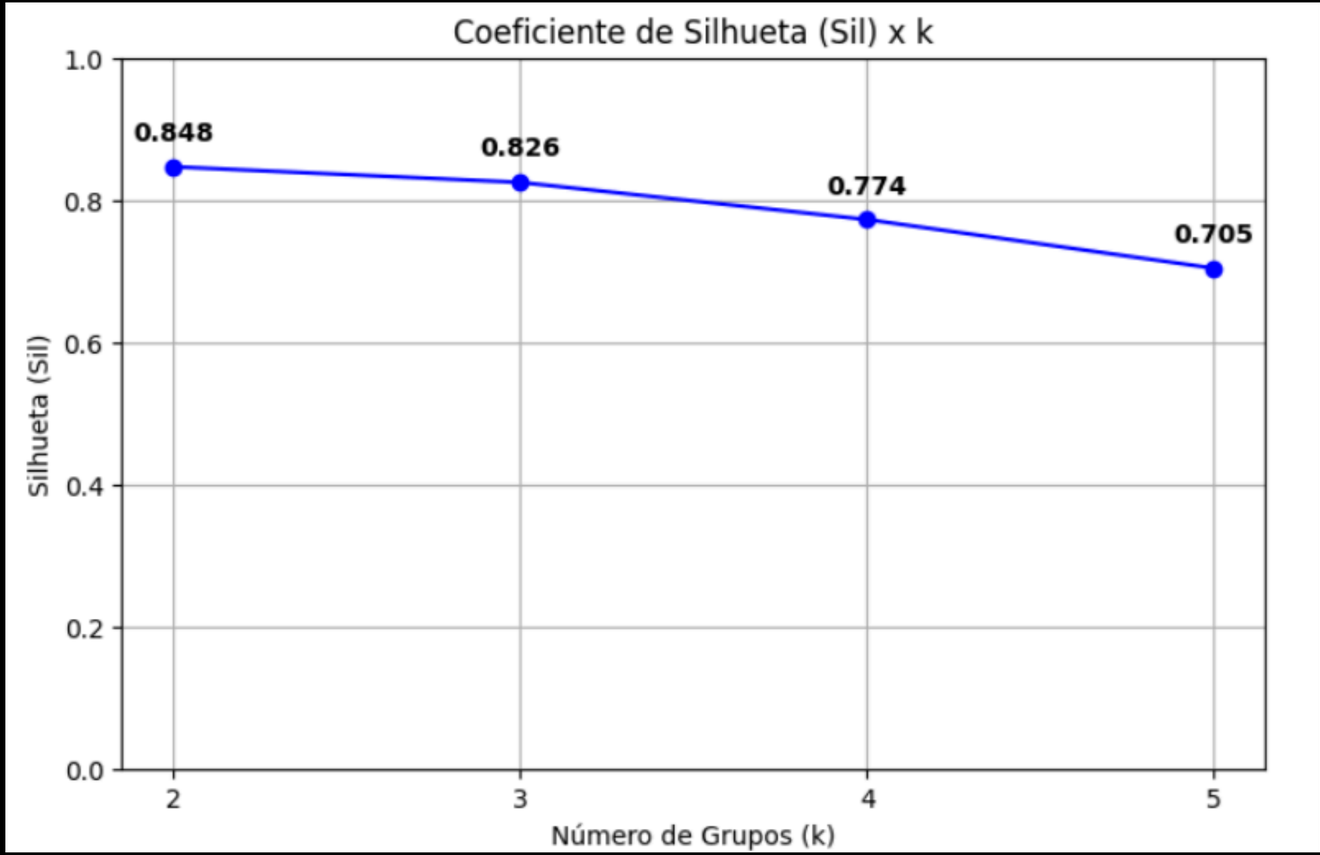


Nova_Classe	
1	4357
2	244

POUCO GANHO
MUITO RISCO

PCA SEM NORMALIZAÇÃO

Redução de 57 para 2 dimensões.

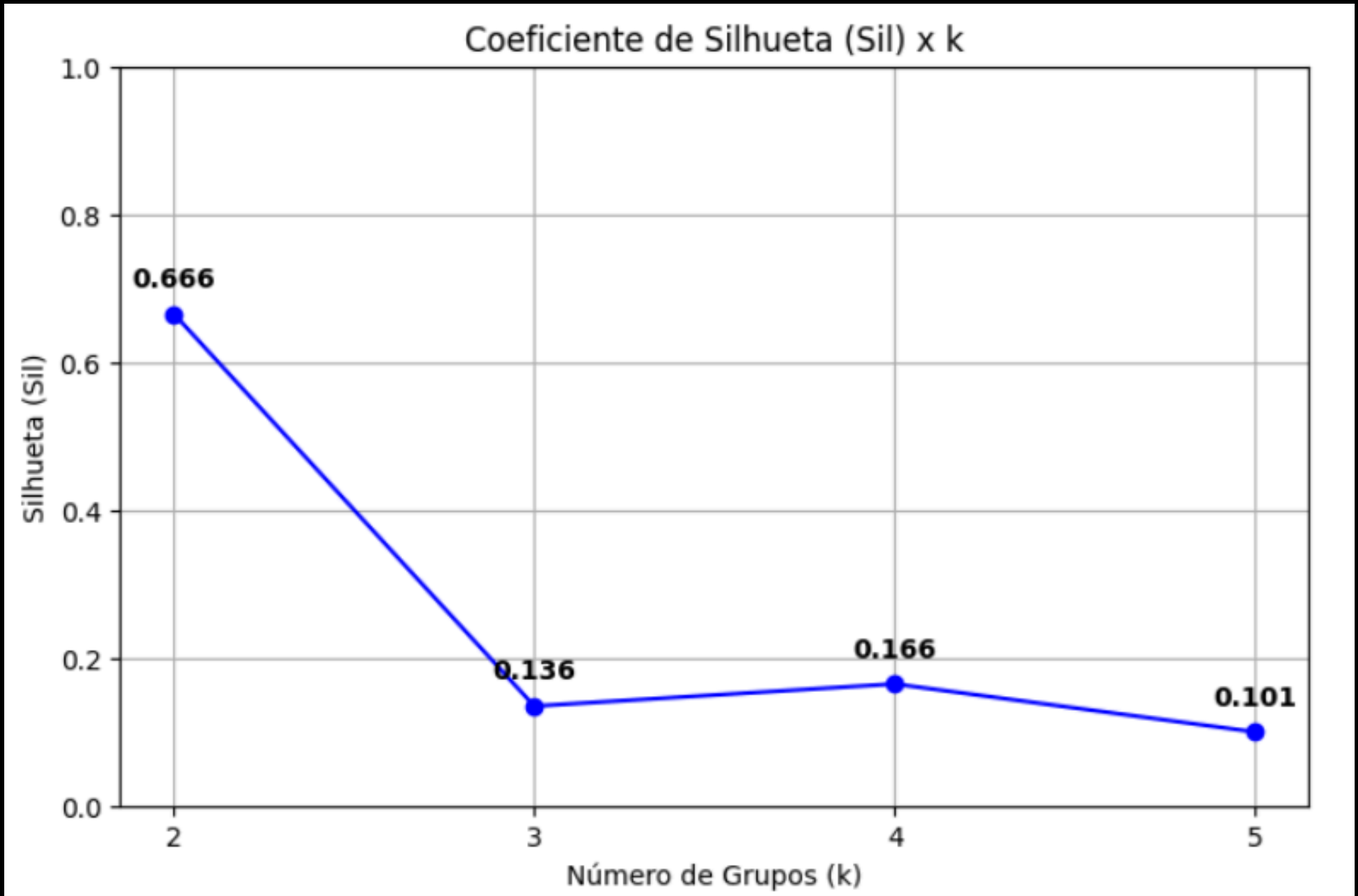


Nova_Classe	
1	4357
2	244

MESMO AGRUPAMENTO DE SEM NORMALIZAÇÃO SEM PCA

PCA COM STANDARD

Redução de 57 para 48 dimensões.



Nova_Classe	
1	4567
2	34

MESMO AGRUPAMENTO DO STANDARD SEM PCA (INCLUSIVE, É O QUE SERÁ UTILZADO - O SEM PCA)

KNN - EXPERIMENTOS

```
param_grid = [
    {
        'knn__n_neighbors': np.arange(1, 21),
        'knn__metric': ['minkowski'],
        'knn__p': [1, 2, 3, 4, 5]
    },
    {
        'knn__n_neighbors': np.arange(1, 21),
        'knn__metric': ['chebyshev']
    }
]
```

CROSS VALIDATION COM **5 FOLDS**

BASEADO EM **F1 MACRO** PARA SELECIONAR HIPERPARÊMETROS

- SEM BALANCEAMENTO
- OVERSAMPLING:

  1) RANDOM SAMPLING
  2) SMOTE

KNN - EXPERIMENTOS

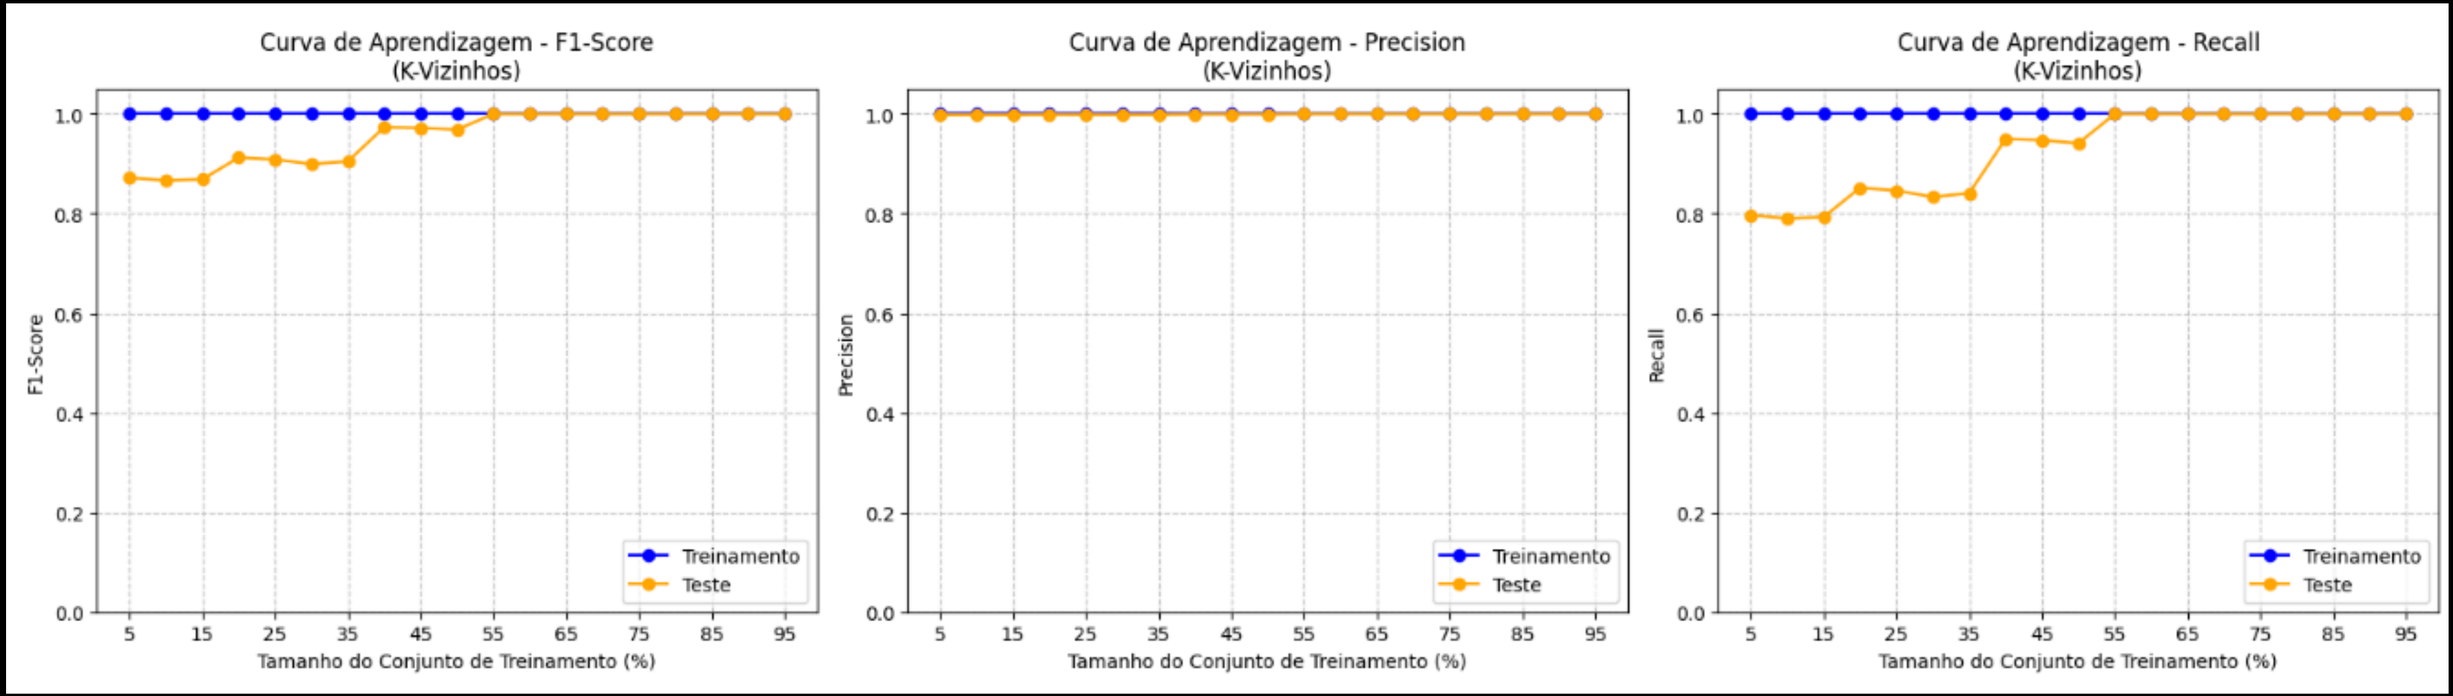
AS TRÊS FORMAS DE BALANCEAMENTO DERAM MESMOS RESULTADOS NO F1 DO CROSS VALIDATION; NA ESCOLHA DOS PARÂMETROS E NO CONJUNTO DE TESTE;

- **K** = 1
- **P** = 2 (EUCLIDIANA)
- **F1-MACRO** = 0.99

	precision	recall	f1-score	support
1	1.00	1.00	1.00	2
2	1.00	1.00	1.00	229
accuracy			1.00	231
macro avg	1.00	1.00	1.00	231
weighted avg	1.00	1.00	1.00	231

CONJUNTO DE TESTE

KNN- CURVA DE APRENDIZAGEM



KNN- CURVA DE APRENDIZAGEM

```
--- Avaliação com 30.0% de dados de treino

Classe 1:
  Contagem exata (Support): 24
  Precision: 1.0000
  Recall: 0.6667
  F1-Score: 0.8000

Classe 2:
  Contagem exata (Support): 3197
  Precision: 0.9975
  Recall: 1.0000
  F1-Score: 0.9988
```

OLHANDO PARA 30% DE TREINAMENTO

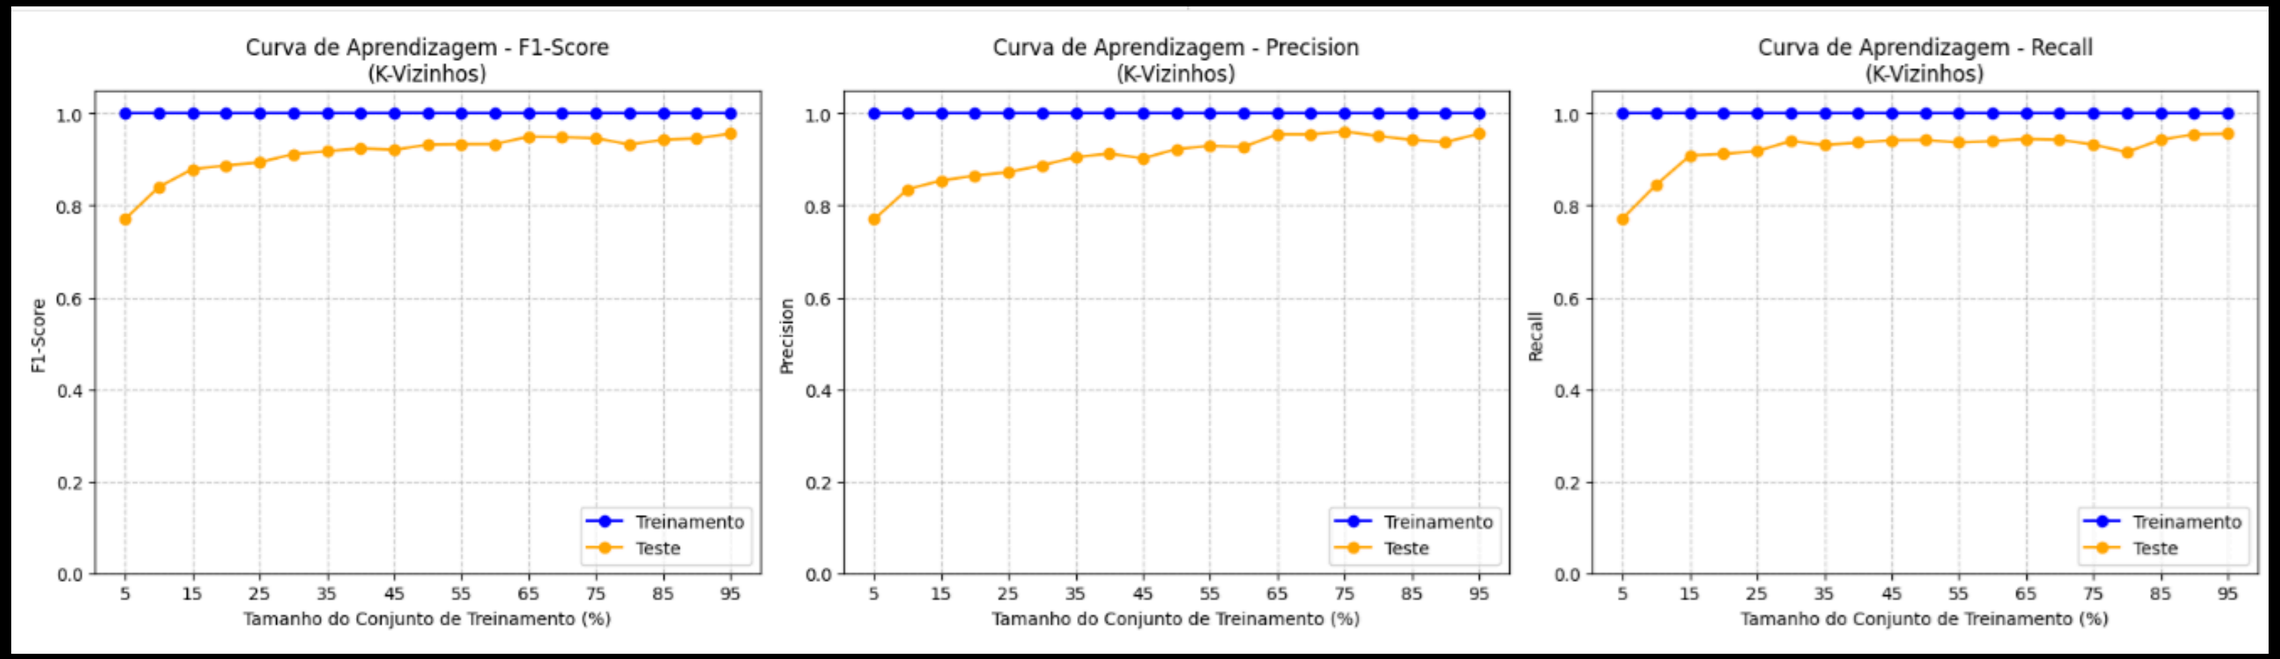
```
Classe 1:
  Contagem exata (Support): 15
  Precision: 1.0000
  Recall: 1.0000
  F1-Score: 1.0000

Classe 2:
  Contagem exata (Support): 2056
  Precision: 1.0000
  Recall: 1.0000
  F1-Score: 1.0000
```

OLHANDO PARA 55% DE TREINAMENTO

KNN- CURVA DE APRENDIZAGEM

ATESTANDO O PORQUÊ DO AGRUPAMENTO GERADO PELO CASO DE SEM NORMALIZAÇÃO SER PIOR



NAIVE BAYES - VALIDAÇÃO CRUZADA + GRIDSEARCH

```
--- TESTE 1: SEM BALANCEAMENTO ---
Melhores parâmetros: {'nb__var_smoothing': np.float64(1e-06)}
F1 CV - Sem balanceamento: 0.7899907025880466

--- TESTE 2: RANDOM OVERSAMPLING ---
Melhores parâmetros: {'nb__var_smoothing': np.float64(1e-07)}
F1 CV - Random Oversampling: 0.7487891436951007

--- TESTE 3: SMOTE OVERSAMPLING ---
Melhores parâmetros: {'nb__var_smoothing': np.float64(1e-07)}
F1 CV - SMOTE: 0.8095511674449316
```

```
--- AVALIAÇÃO NO CONJUNTO DE TESTE ---

Naive Bayes - Sem balanceamento:
              precision    recall  f1-score   support

           1       0.47      1.00      0.64         7
           2       1.00      0.99      1.00       914

    accuracy                           0.99       921
   macro avg       0.73      1.00      0.82       921
weighted avg       1.00      0.99      0.99       921


Naive Bayes - Random Oversampling:
              precision    recall  f1-score   support

           1       0.33      1.00      0.50         7
           2       1.00      0.98      0.99       914

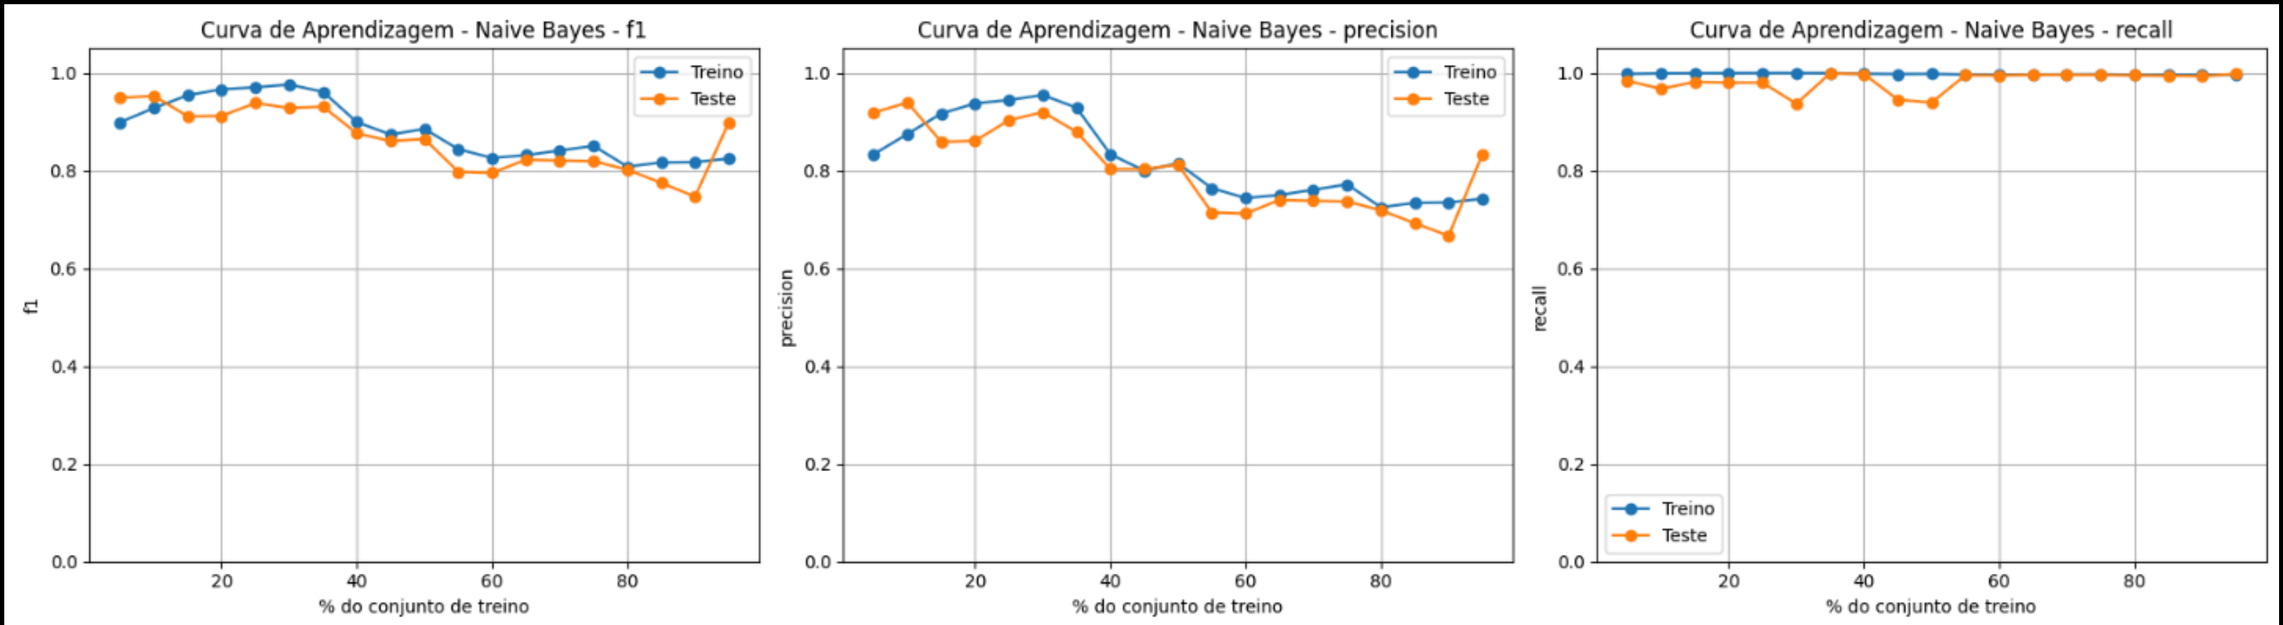
    accuracy                           0.98       921
   macro avg       0.67      0.99      0.75       921
weighted avg       0.99      0.98      0.99       921


Naive Bayes - SMOTE:
              precision    recall  f1-score   support

           1       0.44      1.00      0.61         7
           2       1.00      0.99      1.00       914

    accuracy                           0.99       921
   macro avg       0.72      1.00      0.80       921
weighted avg       1.00      0.99      0.99       921
```

NAIVE BAYES - CURVA DE APRENDIZAGEM



ÁRVORE DE DECISÃO

ÁRVORE DE DECISÃO: OTIMIZAÇÃO E RESULTADOS NO TESTE

```
--- ÁRVORE DE DECISÃO: SEM BALANCEAMENTO ---
Melhores parâmetros: {'dt__criterion': 'gini', 'dt__max_depth': None, 'dt__min_samples_split': 2}
F1 CV - Sem balanceamento: 0.9753

--- ÁRVORE DE DECISÃO: RANDOM OVERSAMPLING ---
Melhores parâmetros: {'dt__criterion': 'gini', 'dt__max_depth': None, 'dt__min_samples_split': 2}
F1 CV - ROS: 0.9627

--- ÁRVORE DE DECISÃO: SMOTE OVERSAMPLING ---
Melhores parâmetros: {'dt__criterion': 'gini', 'dt__max_depth': None, 'dt__min_samples_split': 2}
F1 CV - SMOTE: 0.9719

Relatório de Classificação (Melhor Modelo DT no Teste):
              precision    recall  f1-score   support

           1     0.8750    1.0000    0.9333         7
           2     1.0000    0.9989    0.9995       914

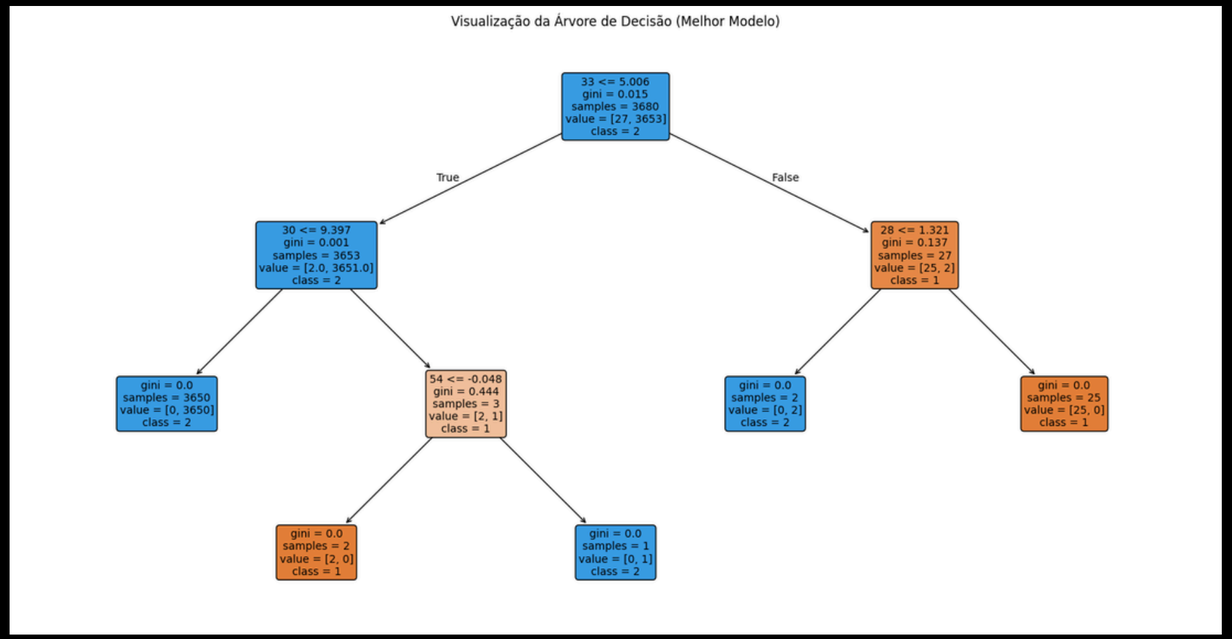
    accuracy                         0.9989       921
   macro avg     0.9375    0.9995    0.9664       921
weighted avg     0.9990    0.9989    0.9990       921
```

ÁRVORE DE DECISÃO: OTIMIZAÇÃO E RESULTADOS NO TESTE

- MELHOR CONFIGURAÇÃO: BASELINE (SEM BALANCEAMENTO) SUPEROU ROS E SMOTE.
- HIPERPARÂMETROS SELECIONADOS: CRITERION: GINI, MAX_DEPTH: NONE, MIN_SAMPLES_SPLIT: 2.
- PERFORMANCE NO TESTE: F1-MACRO DE 0,9664.
- ACURÁCIA ISOLADA: PRECISÃO DE 0,8750 NA CLASSE 1 (MINORIDADE) E RECALL DE 0,9989 NA CLASSE 2 (MAJORIDADE).

MAPEAMENTO LÓGICO: A ESTRUTURA DA ÁRVORE

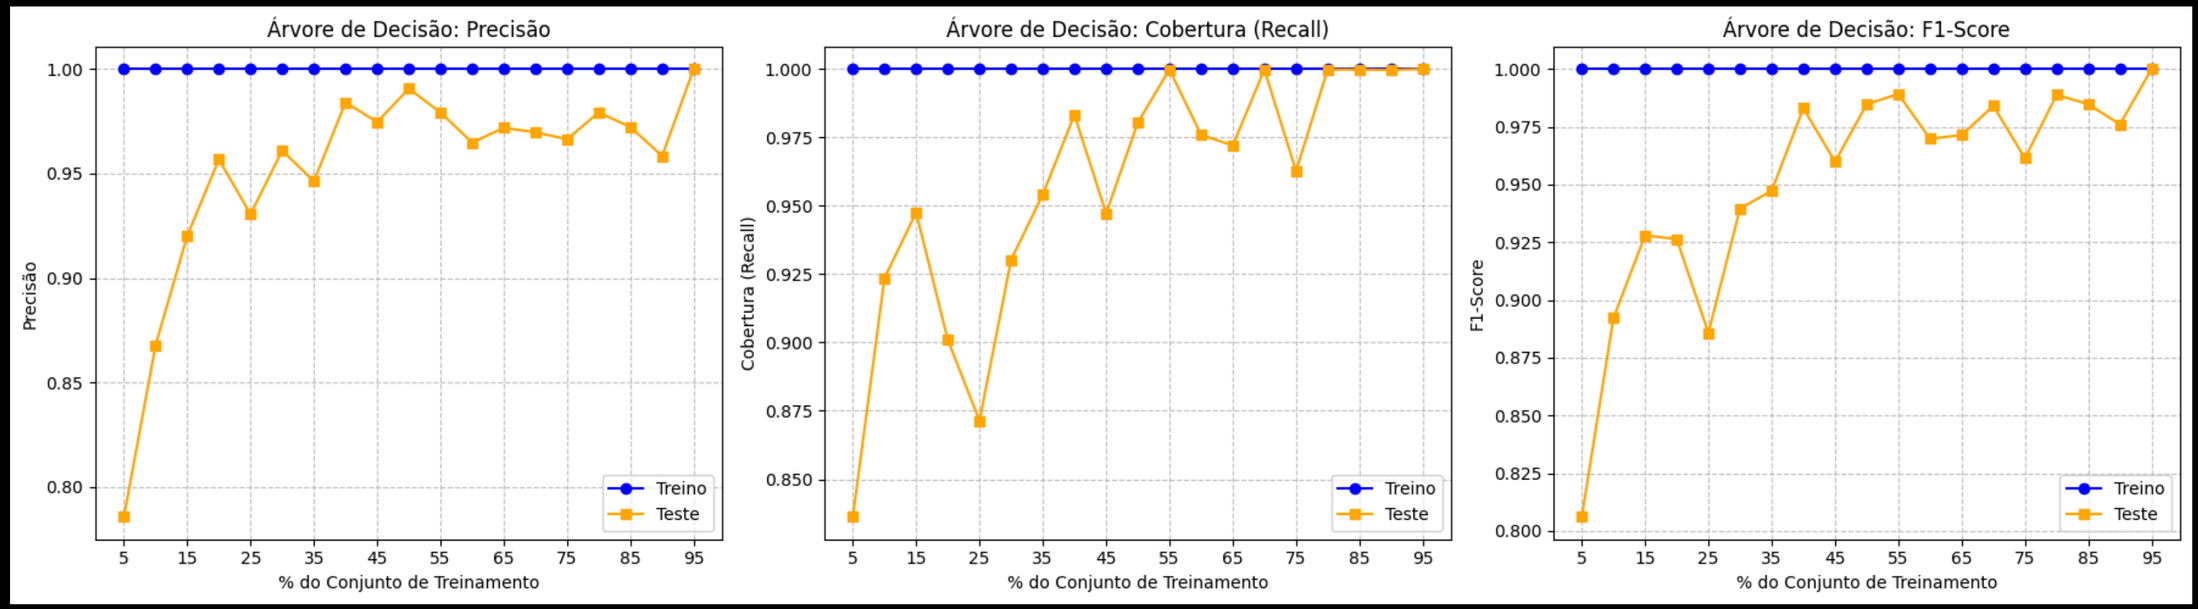
- ENGENHARIA REVERSA: A ÁRVORE RECRIOU AS FRONTEIRAS DO K-MEANS COM POUCAS QUEBRAS.
- VARIÁVEIS CHAVE: DECISÕES BASEADAS PRINCIPALMENTE NAS FEATURES 33, 30, 28 E 54.



DINÂMICA DE TREINAMENTO E VARIÂNCIA

- **REINO (AZUL): CONSTANTE EM 1,00, INDICANDO MEMORIZAÇÃO RÁPIDA DAS FRONTEIRAS.**

- **TESTE (LARANJA): INSTABILIDADE INICIAL MITIGADA COM ALTO VOLUME DE DADOS (CONVERGÊNCIA > 85%).**



RANDOMFOREST

RANDOM FOREST: ESTABILIDADE E PERFEIÇÃO PREDITIVA

```
--- RANDOM FOREST: SEM BALANCEAMENTO ---
Melhores parâmetros: {'rf__max_depth': None, 'rf__min_samples_split': 2, 'rf__n_estimators': 100}
F1 CV - Sem balanceamento: 0.9888

--- RANDOM FOREST: RANDOM OVERSAMPLING ---
Melhores parâmetros: {'rf__max_depth': None, 'rf__min_samples_split': 2, 'rf__n_estimators': 50}
F1 CV - ROS: 0.9811

--- RANDOM FOREST: SMOTE OVERSAMPLING ---
Melhores parâmetros: {'rf__max_depth': None, 'rf__min_samples_split': 2, 'rf__n_estimators': 50}
F1 CV - SMOTE: 0.9811

Relatório de Classificação (Melhor Modelo RF no Teste):
              precision    recall  f1-score   support

           1     1.0000    1.0000    1.0000         7
           2     1.0000    1.0000    1.0000       914

    accuracy                         1.0000       921
   macro avg     1.0000    1.0000    1.0000       921
weighted avg     1.0000    1.0000    1.0000       921
```

RANDOM FOREST: ESTABILIDADE E PERFEIÇÃO PREDITIVA

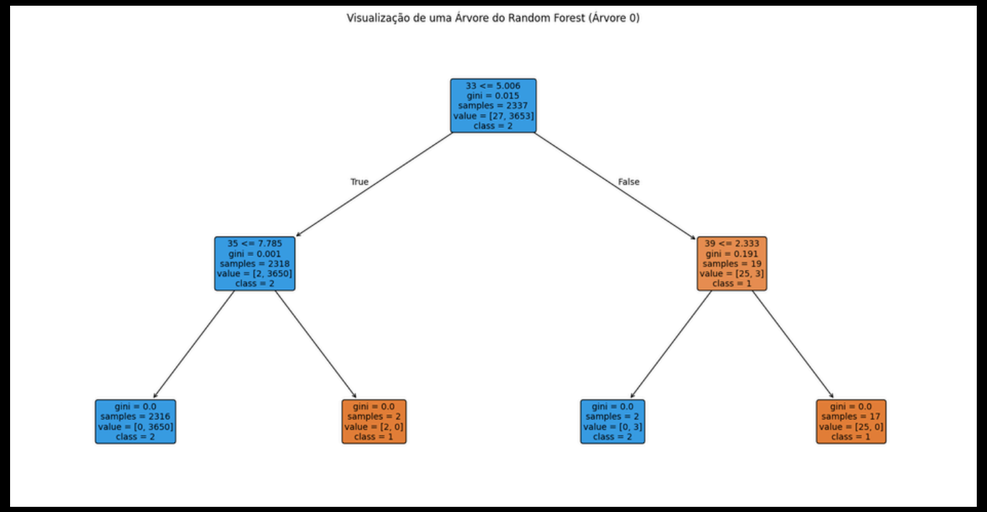
- HIPERPARÂMETROS: BASELINE (SEM BALANCEAMENTO) USANDO UM "BATALHÃO" DE 100 ESTIMADORES.

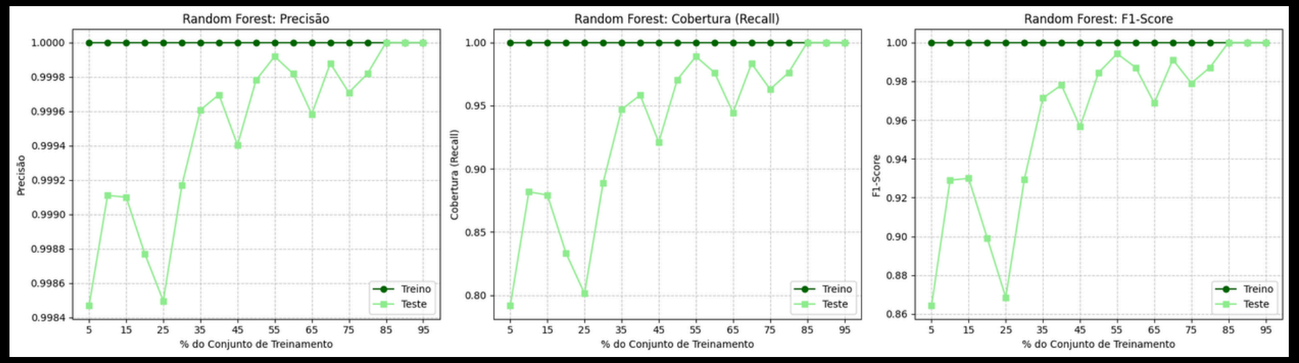
- MÉTRICAS ABSOLUTAS: OBTENÇÃO DE EXATOS 1,0000 (100%) EM PRECISION, RECALL E F1-SCORE PARA AMBAS AS CLASSES NO TESTE ISOLADO.

COMPORTAMENTO DO ENSEMBLE E CONCLUSÃO

- VARIABILIDADE INTERNA: UMA ÁRVORE INDIVIDUAL DA FLORESTA TOMA CAMINHOS LIGEIRAMENTE DIFERENTES, CORTANDO POR VARIÁVEIS COMO 35 E 39.

- CONCLUSÃO DAS CURVAS: A PRECISÃO NO TESTE (GRÁFICO 1) SE MANTEVE QUASE ESTÁTICA ACIMA DE 99,8% DESDE OS PRIMEIROS 5% DE DADOS.





REGRESSÃO LOGÍSTICA

MODELAGEM COM REGRESSÃO LOGÍSTICA

- DIVISÃO DOS DADOS: 80% PARA TREINO/VALIDAÇÃO CRUZADA (5 FOLDS) E 20% PARA TESTE, MANTENDO A PROPORÇÃO ESTRATIFICADA.

- PIPELINE SEGURO: USO DO STANDARDSCALER ISOLADO EM CADA FOLD DE TREINO PARA EVITAR VAZAMENTO DE DADOS, DADO QUE O MODELO É SENSÍVEL À ESCALA.

- ABORDAGEM: TESTE DE TRÊS CENÁRIOS (SEM BALANCEAMENTO, RANDOM OVERSAMPLING E SMOTE) OTIMIZADOS VIA GRIDSEARCHCV PARA ENCONTRAR O HIPERPLANO IDEAL.

MODELAGEM COM REGRESSÃO LOGÍSTICA

- VALIDAÇÃO CRUZADA: MODELO SEM BALANCEAMENTO VENCEU COM F1-CV PERFEITO (1.0).
- HIPERPARÂMETROS: C=0.1, PENALTY=L2 E SOLVER=LBFGS.
- CONJUNTO DE TESTE: O MODELO DETECTOU 100% DA CLASSE MINORITÁRIA (RECALL 1.00) COM PRECISÃO DE 0.88.

```
--- TESTE 1: SEM BALANCEAMENTO ---
Melhores parâmetros: {'lr__C': 0.1, 'lr__max_iter': 5000, 'lr__penalty': 'l2', 'lr__solver': 'lbfgs'}
F1 CV - Sem balanceamento: 1.0

--- TESTE 2: RANDOM OVERSAMPLING ---
Melhores parâmetros: {'lr__C': 1, 'lr__max_iter': 5000, 'lr__penalty': 'l2', 'lr__solver': 'lbfgs'}
F1 CV - Random Oversampling: 0.9753189490628851

--- TESTE 3: SMOTE OVERSAMPLING ---
Melhores parâmetros: {'lr__C': 1, 'lr__max_iter': 5000, 'lr__penalty': 'l2', 'lr__solver': 'lbfgs'}
F1 CV - SMOTE: 0.97641775614245
              precision    recall  f1-score   support

           1       0.88      1.00      0.93         7
           2       1.00      1.00      1.00       914

    accuracy                           1.00       921
   macro avg       0.94      1.00      0.97       921
weighted avg       1.00      1.00      1.00       921

              precision    recall  f1-score   support

           1       0.88      1.00      0.93         7
           2       1.00      1.00      1.00       914

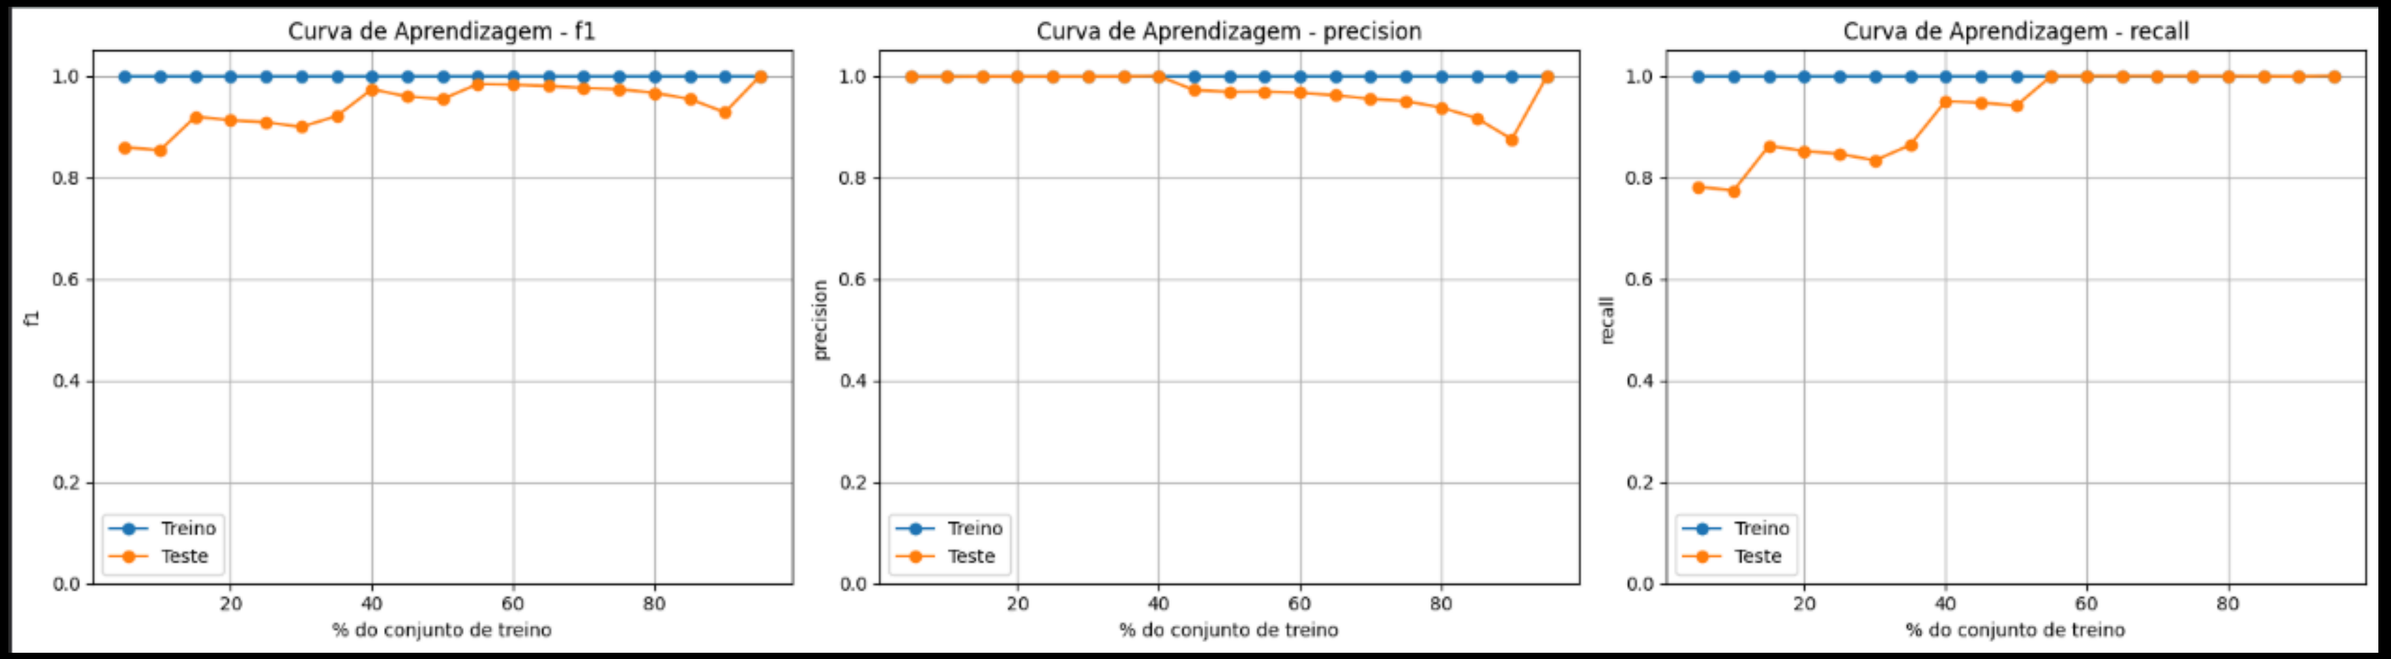
    accuracy                           1.00       921
   macro avg       0.94      1.00      0.97       921
weighted avg       1.00      1.00      1.00       921

              precision    recall  f1-score   support

           1       0.88      1.00      0.93         7
           2       1.00      1.00      1.00       914

    accuracy                           1.00       921
   macro avg       0.94      1.00      0.97       921
weighted avg       1.00      1.00      1.00       921
```

MODELAGEM COM REGRESSÃO LOGÍSTICA



- APRENDIZADO INICIAL: AJUSTE PROGRESSIVO DOS PESOS ENTRE 5% E 25% DE VOLUME DE TREINO.
- ESTABILIDADE: LINHAS DE TREINO E TESTE COESAS E CONVERGINDO PARA O TOPO.
- CONCLUSÃO: AUSÊNCIA DE OVERFITTING E CONFIRMAÇÃO DE QUE OS CLUSTERS DO K-MEANS ERAM LINEARMENTE SEPARÁVEIS.

CONCLUSÃO